

Econometría Avanzada

Modelo de regresión y estimación por MCO

Manuel Fernández

12 de agosto de 2026

Temas de la clase:

1. Modelo de regresión
2. Modelo de regresión y causalidad
3. Estimación por mínimos cuadrados ordinarios (MCO)
4. Interpretación de coeficientes y el teorema de Frisch-Waugh-Lovell
5. Sesgo de variable omitida
6. Anexos
 - Teorema de Frisch-Waugh-Lovell

Modelo de regresión

- El objetivo es modelar el **valor esperado (promedio) condicional** de la **variable dependiente** Y_i como una función de las **variables explicativas** $\mathbf{X}_i$:

$$\mathbb{E}[Y_i \mid \mathbf{X}_i] = m(\mathbf{X}_i),$$

donde $m(\mathbf{X}_i)$ es la **función de esperanza condicional (CEF)** y


$\mathbf{X}_i = (x_{i1}, \dots, x_{iK})'$ es un vector de dimensión $K \times 1$.

- Ejemplo:** si Y_i representa el logaritmo del ingreso y $\mathbf{X}_i$ es un escalar ($K = 1$) que indica años de educación:

$$\mathbb{E}[Y_i \mid \mathbf{X}_i = 12] = m(12),$$

que se interpreta como el promedio poblacional del logaritmo del ingreso para las personas con 12 años de educación.

Ejemplo de una CEF



Nota: Tomado de Angrist and Pischke (2011).

- La distribución de (log) ingresos se muestra para algunos valores de escolaridad: 4, 8, 12 y 16 años.

Teorema: Descomposición de la CEF

Para cualquier $(Y_i, \mathbf{X}_i)$, se tiene la identidad

$$Y_i = m(\mathbf{X}_i) + \epsilon_i,$$

y el residuo $\epsilon_i \equiv Y_i - m(\mathbf{X}_i)$ cumple: $\mathbb{E}[\epsilon_i | \mathbf{X}_i] = 0$ y $\mathbb{E}[\epsilon_i] = 0$.

Interpretación: Y_i se descompone en una parte “explicada por $\mathbf{X}_i$ ” (la CEF) y un residuo no correlacionado con *ninguna función* de $\mathbf{X}_i$.

■ Demostración breve:

$$\begin{aligned}\mathbb{E}[\epsilon_i | \mathbf{X}_i] &= \mathbb{E}[Y_i - m(\mathbf{X}_i) | \mathbf{X}_i] \\ &= \mathbb{E}[Y_i | \mathbf{X}_i] - m(\mathbf{X}_i) \\ &= m(\mathbf{X}_i) - m(\mathbf{X}_i) = 0.\end{aligned}$$

Sea $h(\mathbf{X}_i)$ cualquier función de $\mathbf{X}_i$. Por la *ley de esperanzas iteradas* (LEI):

$$\mathbb{E}[\epsilon_i] = \mathbb{E}[\mathbb{E}[\epsilon_i | \mathbf{X}_i]] = 0, \text{ y}$$

$$\mathbb{E}[\epsilon_i h(\mathbf{X}_i)] = \mathbb{E}[\mathbb{E}[\epsilon_i h(\mathbf{X}_i) | \mathbf{X}_i]] = \mathbb{E}[h(\mathbf{X}_i) \mathbb{E}[\epsilon_i | \mathbf{X}_i]] = 0.$$

Teorema: Propiedad de predicción de la CEF

Para cualquier función $h(\mathbf{X}_i)$, la CEF resuelve

$$m(\mathbf{X}_i) = \arg \min_{h(\mathbf{X}_i)} \mathbb{E}[(Y_i - h(\mathbf{X}_i))^2].$$

Interpretación: La CEF es el predictor que minimiza el error cuadrático medio de predicción (MSE) de Y_i dado $\mathbf{X}_i$.

Demostración breve. Sea $\epsilon_i = Y_i - m(\mathbf{X}_i)$. Para cualquier $h(\mathbf{X}_i)$:

$$\begin{aligned}(Y_i - h(\mathbf{X}_i))^2 &= \left(\epsilon_i + m(\mathbf{X}_i) - h(\mathbf{X}_i) \right)^2 \\ &= \epsilon_i^2 + 2\epsilon_i \left(m(\mathbf{X}_i) - h(\mathbf{X}_i) \right) + \left(m(\mathbf{X}_i) - h(\mathbf{X}_i) \right)^2.\end{aligned}$$

Tomando esperanza y usando $\mathbb{E}[\epsilon_i | \mathbf{X}_i] = 0$:

$$\mathbb{E}[(Y_i - h(\mathbf{X}_i))^2] = \mathbb{E}[\epsilon_i^2] + \mathbb{E}[(m(\mathbf{X}_i) - h(\mathbf{X}_i))^2] \geq \mathbb{E}[\epsilon_i^2],$$

con igualdad si $h(\mathbf{X}_i) = m(\mathbf{X}_i)$.

¿Qué CEF debemos usar?

- La CEF verdadera es desconocida, así que en la práctica la **aproximamos** con una forma funcional específica. Un caso común es asumir un modelo **lineal**:

$$\begin{aligned}m(\mathbf{X}_i) &\approx x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K \\ &= \mathbf{X}_i'\boldsymbol{\beta}\end{aligned}$$

donde $\boldsymbol{\beta} = (\beta_1, \dots, \beta_K)'$ es un vector de parámetros $K \times 1$ **que desconocemos**.

Nota 1: El modelo es lineal en los *parámetros*, no necesariamente en las variables explicativas.

- El modelo que resulta es:

$$Y_i = \mathbf{X}_i'\boldsymbol{\beta} + e_i.$$

Nota 2: $e_i \neq \epsilon_i$ a menos que la CEF esté correctamente especificada.

- Suponga que definimos β como

$$\beta = \arg \min_b \mathbb{E}[(Y_i - \mathbf{X}_i' b)^2]. \quad (1)$$

La **condición de primer orden** evaluada en β es:

$$\mathbb{E}[\mathbf{X}_i \underbrace{(Y_i - \mathbf{X}_i' \beta)}_{e_i}] = \mathbf{0}.$$

Nota 3: Por construcción, $\mathbf{X}_i$ no está correlacionado con e_i ; esto **no es un supuesto**.

- Resolviendo:

$$\beta = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1} \mathbb{E}[\mathbf{X}_i Y_i].$$

Nota 4: Para invertir $\mathbb{E}[\mathbf{X}_i \mathbf{X}_i']$ se requiere que $\text{rank}(\mathbb{E}[\mathbf{X}_i \mathbf{X}_i']) = K$.

Justificación 1

Si la CEF verdadera es lineal: $m(\mathbf{X}_i) = \mathbf{X}_i' \boldsymbol{\beta}^*$, entonces $\boldsymbol{\beta} = \boldsymbol{\beta}^*$.

Justificación 2

Aun si la CEF verdadera no es lineal, la función $\mathbf{X}_i' \boldsymbol{\beta}$ es el *mejor predictor lineal* de Y_i dado $\mathbf{X}_i$ en el sentido de que minimiza el MSE.

Interpretación: La regresión proporciona el mejor **predictor lineal** de la variable dependiente, de la misma forma en que la CEF es el mejor **predictor sin restricciones** de la variable dependiente.


Justificación 3

La función $\mathbf{X}_i' \boldsymbol{\beta}$ cumple

$$\boldsymbol{\beta} = \arg \min_b \mathbb{E}[(m(\mathbf{X}_i) - \mathbf{X}_i' b)^2].$$

Interpretación: $\mathbf{X}_i' \boldsymbol{\beta}$ es el **mejor predictor lineal** de la CEF en el sentido de que minimiza el MSE.

La regresión como aproximación lineal de la CEF



Nota: Tomado de Angrist and Pischke (2011).

Modelo de regresión y causalidad

Ejemplo usando resultados potenciales

- Un modelo de regresión puede o no tener una interpretación causal.
- **Ejemplo:** sea Y_i el resultado **observado** (e.g., la nota del estudiante i), y $D_i \in \{0, 1\}$ una variable indicadora de tratamiento (e.g., si i lee la bibliografía).

Los **resultados potenciales** son: $Y_i(1)$ y $Y_i(0)$, y el **efecto causal** es:

$$\tau_i = Y_i(1) - Y_i(0).$$

Para simplificar, vamos a asumir que $\tau_i = \tau$ para todo i . La variable observada se puede expresar como

$$Y_i = Y_i(0) + \tau D_i.$$

- Considere el **modelo lineal**:

$$Y_i = \alpha + \tau D_i + e_i,$$

donde $\alpha \equiv \mathbb{E}[Y_i(0)]$ y $e_i \equiv Y_i(0) - \mathbb{E}[Y_i(0)]$.

Ejemplo usando resultados potenciales (cont.)

- La **diferencia de medias condicionales** entre tratados y no tratados es

$$\mathbb{E}[Y_i|D_i = 1] - \mathbb{E}[Y_i|D_i = 0] = \tau + \underbrace{\mathbb{E}[e_i|D_i = 1] - \mathbb{E}[e_i|D_i = 0]}_{\text{Sesgo de selección}}$$

Necesitamos que $\mathbb{E}[e_i|D_i] = 0$ para recuperar τ .

- Independencia:** si $Y_i(0), Y_i(1) \perp\!\!\!\perp D_i$,

$$\begin{aligned}\mathbb{E}[e_i|D_i] &= \mathbb{E}\left[Y_i(0) - \mathbb{E}[Y_i(0)]|D_i\right] \\ &= \mathbb{E}[Y_i(0)|D_i] - \mathbb{E}[Y_i(0)] \\ &= \mathbb{E}[Y_i(0)] - \mathbb{E}[Y_i(0)] \\ &= 0.\end{aligned}$$

Si el tratamiento se asigna de forma *independiente* de los resultados potenciales, no hay **sesgo de selección**.

Estimación por mínimos cuadrados ordinarios (MCO)

Estimación por mínimos cuadrados ordinarios (MCO)

- Hasta ahora la discusión se planteó en términos **poblacionales**, pero en la práctica trabajamos con una **muestra**.
- Suponga que tiene una muestra aleatoria $\{(Y_i, \mathbf{X}_i) : i = 1, \dots, N\}$. El objetivo es estimar el vector de **parámetros** β del modelo:

$$Y_i = \mathbf{X}_i' \beta + e_i.$$

- Sea $\hat{Y}_i \equiv \mathbf{X}_i' \hat{\beta}$ el **valor predicho** y $\hat{e}_i \equiv Y_i - \hat{Y}_i$ el **error de predicción (muestral)** para una unidad i . Definimos

$$\begin{aligned} S(\hat{\beta}) &\equiv \sum_i \hat{e}_i^2 = \sum_i (Y_i - \hat{Y}_i)^2 \\ &= \sum_i (Y_i - \mathbf{x}_i' \hat{\beta})^2 \\ &= (\mathbf{Y} - \mathbf{X} \hat{\beta})' (\mathbf{Y} - \mathbf{X} \hat{\beta}), \end{aligned}$$

donde $\mathbf{Y}$ es un vector $N \times 1$ y $\mathbf{X}$ es una matriz $N \times K$.

- Estimador MCO:

$$\hat{\beta}_{mco} = \arg \min_{\hat{\beta} \in \mathbb{R}^K} S(\hat{\beta})$$

Expandiendo $S(\hat{\beta})$,

$$S(\hat{\beta}) = \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\hat{\beta} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta}.$$

1. Condiciones de primer orden:

$$\frac{\partial S(\hat{\beta})}{\partial \hat{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta}_{mco} = \mathbf{0},$$

$$\mathbf{X}'\mathbf{X}\hat{\beta}_{mco} = \mathbf{X}'\mathbf{Y}.$$

- Resolviendo para $\hat{\beta}_{mco}$,

$$\hat{\beta}_{mco} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

De forma alternativa,

$$\hat{\beta}_{mco} = \left(\frac{1}{N} \sum_i \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{N} \sum_i \mathbf{x}_i Y_i \right)$$

¿Le resulta conocido?

- $\hat{\beta}_{mco}$ es una función de la muestra $\implies$ es una **variable aleatoria**.

2. Condiciones de segundo orden:

$$\frac{\partial^2 S(\hat{\beta})}{\partial \hat{\beta} \partial \hat{\beta}'} = 2\mathbf{X}'\mathbf{X}$$

- Si $\text{rank}(\mathbf{X}) = K$ (no hay multicolinealidad perfecta), $\mathbf{X}'\mathbf{X}$ es una **matriz definida positiva** $\implies$ la solución $\hat{\beta}_{mco}$ es un mínimo y es **único**.
- Análogo a que la segunda derivada sea estrictamente positiva en una función univariada.

Interpretación de coeficientes y el teorema de Frisch-Waugh-Lovell

Interpretación de coeficientes

- Suponga que quiere estimar el coeficiente τ en el siguiente modelo:

$$Y_i = \tau D_i + \mathbf{X}_i' \boldsymbol{\beta} + e_i, \quad (2)$$

donde D_i es la variable explicativa de interés (binaria o no binaria) y $\mathbf{X}_i$ es un vector de controles que incluye una constante.

- ¿Cuál es el papel de estos controles en la estimación de τ ? Para entenderlo, considere los siguientes modelos auxiliares:

$$Y_i = \mathbf{X}_i' \boldsymbol{\gamma} + \eta_i, \quad (3)$$

$$D_i = \mathbf{X}_i' \boldsymbol{\theta} + \mu_i, \quad (4)$$

y las variables residuales correspondientes:

$$\hat{\eta}_i = Y_i - \mathbf{X}_i' \hat{\boldsymbol{\gamma}},$$

$$\hat{\mu}_i = D_i - \mathbf{X}_i' \hat{\boldsymbol{\theta}},$$

donde $\hat{\boldsymbol{\gamma}}$ y $\hat{\boldsymbol{\theta}}$ son los estimadores de MCO.

Teorema de Frisch-Waugh-Lovell

- Considere ahora el siguiente modelo residual:

$$\hat{\eta}_i = \phi \hat{\mu}_i + \nu_i, \quad (5)$$

que relaciona las partes de Y_i y D_i que no están explicadas por los controles $\mathbf{X}_i$.

- El Teorema de Frisch-Waugh-Lovell establece que:

$$\hat{\tau} = \hat{\phi},$$

es decir, el coeficiente estimado $\hat{\tau}$ del modelo original es igual al coeficiente estimado $\hat{\phi}$ obtenido del modelo residual (5)  Demostración. ¿Intuición?

- Este resultado es más general y se aplica a cualquier partición del vector de variables explicativas en un modelo de regresión.

Sesgo de variable omitida

- El teorema FWL muestra qué hace **incluir** un control. La pregunta opuesta: ¿qué pasa si **omitimos** una variable relevante?
- Volvamos al ejemplo: Y_i es la nota del estudiante i y D_i indica si lee la bibliografía. Suponga que el modelo correcto (la **regresión larga**) incluye la habilidad W_i :

$$Y_i = \alpha + \tau D_i + \lambda W_i + e_i, \quad \text{con} \quad \mathbb{E}[e_i \mid D_i, W_i] = 0; \quad (6)$$

es decir, una vez condicionamos en la habilidad, no hay sesgo de selección.

- La habilidad **no es observable**, así que trabajamos con la **regresión corta**:

$$Y_i = \alpha_c + \tau_c D_i + \tilde{e}_i, \quad (7)$$

donde α_c y τ_c son los coeficientes de la regresión de Y_i sobre $(1, D_i)$.

- ¿Qué relación hay entre τ_c y el efecto causal τ ?

- La clave es la regresión de la variable **omitida** sobre la **incluida**:

$$W_i = \delta_0 + \delta_1 D_i + u_i, \quad (8)$$

donde, por construcción, $\mathbb{E}[u_i] = 0$ y $\mathbb{E}[D_i u_i] = 0$.

- Sustituyendo (8) en la regresión larga (6):

$$\begin{aligned} Y_i &= \alpha + \tau D_i + \lambda (\delta_0 + \delta_1 D_i + u_i) + e_i \\ &= \underbrace{(\alpha + \lambda \delta_0)}_{= \alpha_c} + \underbrace{(\tau + \lambda \delta_1)}_{= \tau_c} D_i + \underbrace{(e_i + \lambda u_i)}_{= \tilde{e}_i} \end{aligned}$$

- El error $\tilde{e}_i$ tiene media cero y es ortogonal a D_i ($\mathbb{E}[D_i e_i] = 0$ por (6) y $\mathbb{E}[D_i u_i] = 0$ por construcción); por lo tanto, los coeficientes señalados son los de la regresión corta (7). En particular:

$$\tau_c = \tau + \underbrace{\lambda \delta_1}_{\text{Sesgo de variable omitida}}$$

- **Regla:** sesgo = (efecto de la omitida en la regresión larga, λ) $\times$ (relación entre la omitida y la incluida, δ_1).
- Dirección del sesgo:

	$\delta_1 > 0$	$\delta_1 < 0$
$\lambda > 0$	$\tau_c > \tau$	$\tau_c < \tau$
$\lambda < 0$	$\tau_c < \tau$	$\tau_c > \tau$

- **En el ejemplo:** si la habilidad mejora la nota ($\lambda > 0$) y los estudiantes más hábiles leen más la bibliografía ($\delta_1 > 0$), entonces τ_c **sobreestima** el efecto causal de leer la bibliografía.
- No hay sesgo si $\lambda = 0$ (la variable omitida no pertenece al modelo) o si $\delta_1 = 0$ (la variable omitida no se relaciona con D_i).
- El sesgo es un problema de **identificación**, no de tamaño de muestra: no desaparece con más datos.

- El **sesgo de variable omitida** es el **sesgo de selección** expresado en el lenguaje de regresión: quienes leen la bibliografía difieren en habilidad de quienes no la leen. Al omitir W_i , el término λW_i queda en el error, que ya no tiene media condicional cero dado D_i .
- Buena parte del curso consiste en **estrategias para eliminar este sesgo**:
 - **Aleatorización** (RCT): garantiza $\delta_1 = 0$ por diseño.
 - **Selección en observables** (regresión, matching, PSM): controlar por W_i cuando es observable.
 - **RD, IV, DiD**: estrategias que no requieren observar W_i .

Anexos

Demostración del teorema de Frisch-Waugh-Lovell

- Los tres **modelos estimados** por MCO son:

$$Y_i = \hat{\tau} D_i + \mathbf{X}_i' \hat{\beta} + \hat{e}_i,$$

$$Y_i = \mathbf{X}_i' \hat{\gamma} + \hat{\eta}_i,$$

$$D_i = \mathbf{X}_i' \hat{\theta} + \hat{\mu}_i.$$

- Las **condiciones de primer orden** de cada estimación implican que los residuos son **ortogonales** a sus variables explicativas:

$$\sum_i D_i \hat{e}_i = 0; \quad \sum_i \mathbf{X}_i \hat{e}_i = \mathbf{0}; \quad \sum_i \mathbf{X}_i \hat{\eta}_i = \mathbf{0}; \quad \sum_i \mathbf{X}_i \hat{\mu}_i = \mathbf{0}.$$

- El estimador MCO del modelo residual (5), que no incluye constante, es:

$$\hat{\phi} = \frac{\sum_i \hat{\mu}_i \hat{\eta}_i}{\sum_i \hat{\mu}_i^2}.$$

- Objetivo:** demostrar que $\hat{\phi} = \hat{\tau}$.

- **Paso 1:** expresar $\hat{\eta}_i$ en términos de $\hat{\mu}_i$. Sustituyendo el modelo original estimado en la definición de $\hat{\eta}_i$:

$$\begin{aligned}\hat{\eta}_i &= Y_i - \mathbf{X}_i' \hat{\gamma} \\ &= \hat{\tau} D_i + \mathbf{X}_i' \hat{\beta} + \hat{e}_i - \mathbf{X}_i' \hat{\gamma} \\ &= \hat{\tau} \underbrace{(\hat{\mu}_i + \mathbf{X}_i' \hat{\theta})}_{= D_i} + \mathbf{X}_i' (\hat{\beta} - \hat{\gamma}) + \hat{e}_i \\ &= \hat{\tau} \hat{\mu}_i + \mathbf{X}_i' (\hat{\tau} \hat{\theta} + \hat{\beta} - \hat{\gamma}) + \hat{e}_i.\end{aligned}$$

- El residuo $\hat{\eta}_i$ tiene tres componentes: $\hat{\tau} \hat{\mu}_i$, una **combinación lineal de $\mathbf{X}_i$** y el residuo $\hat{e}_i$.

Demostración del teorema de Frisch-Waugh-Lovell

- **Paso 2:** multiplicar por $\hat{\mu}_i$, sumar sobre i y usar la ortogonalidad:

$$\sum_i \hat{\mu}_i \hat{\eta}_i = \hat{\tau} \sum_i \hat{\mu}_i^2 + \underbrace{\left(\sum_i \hat{\mu}_i \mathbf{x}_i' \right)}_{=0'} (\hat{\tau} \hat{\boldsymbol{\theta}} + \hat{\beta} - \hat{\gamma}) + \underbrace{\sum_i \hat{\mu}_i \hat{e}_i}_{=0}.$$

El último término es cero porque

$$\sum_i \hat{\mu}_i \hat{e}_i = \sum_i (D_i - \mathbf{x}_i' \hat{\boldsymbol{\theta}}) \hat{e}_i = \underbrace{\sum_i D_i \hat{e}_i}_{=0} - \hat{\boldsymbol{\theta}}' \underbrace{\sum_i \mathbf{x}_i \hat{e}_i}_{=0} = 0.$$

- **Paso 3:** como $\sum_i \hat{\mu}_i \hat{\eta}_i = \hat{\tau} \sum_i \hat{\mu}_i^2$,

$$\hat{\phi} = \frac{\sum_i \hat{\mu}_i \hat{\eta}_i}{\sum_i \hat{\mu}_i^2} = \hat{\tau}.$$

- **Observación 1:** el resultado requiere $\sum_i \hat{\mu}_i^2 > 0$; es decir, que D_i no sea una combinación lineal exacta de los controles $\mathbf{X}_i$ (no multicolinealidad perfecta).
- **Observación 2:** el modelo residual (5) no necesita constante: como $\mathbf{X}_i$ incluye una constante, $\sum_i \hat{\eta}_i = 0$ y $\sum_i \hat{\mu}_i = 0$, así que una constante adicional tendría coeficiente estimado igual a cero.
- **Observación 3:** el mismo argumento, con D_i (y por tanto $\hat{\mu}_i$) vectorial, demuestra la versión general del teorema para cualquier partición del vector de variables explicativas.