

Econometría Avanzada

Experimentos Sociales Controlados (RCTs)

Manuel Fernández


7 de septiembre de 2026

Temas de la Clase:

1. El problema de selección
2. Aleatorización
3. SUTVA
4. Verificación de la aleatorización
5. Inferencia por aleatorización
6. No todo es perfecto

Crecimiento de los métodos experimentales en economía

- Historia larga de uso de métodos experimentales en otras disciplinas.
- En economía, su adopción es más reciente y ha estado fuertemente impulsada por las **evaluaciones de impacto**.



Fuente: Ravallion (2020)

Banerjee, Duflo y Kremer



© Nobel Media. Photo: A. Mahmoud

Abhijit Banerjee

Prize share: 1/3



© Nobel Media. Photo: A. Mahmoud

Esther Duflo

Prize share: 1/3



© Nobel Media. Photo: A. Mahmoud

Michael Kremer

Prize share: 1/3

- Nobel en 2019 “for their *experimental approach* to alleviating global poverty.”

El problema de selección

Recordando el problema de selección

- Nos interesa estimar el **efecto causal** de un tratamiento sobre una variable de resultado Y_i . Sea D_i una variable indicadora:

$$D_i = \begin{cases} 1 & \text{si } i \text{ recibe el tratamiento} \\ 0 & \text{si } i \text{ no recibe el tratamiento} \end{cases}$$

- Cada unidad tiene dos **resultados potenciales**:

$$Y_i = \begin{cases} Y_i(1) & \text{si } i \text{ recibe el tratamiento} \\ Y_i(0) & \text{si } i \text{ no recibe el tratamiento} \end{cases}$$

- Definimos el **efecto causal** como la diferencia de los **resultados potenciales**:

$$\tau_i \equiv Y_i(1) - Y_i(0).$$

Problema fundamental de la inferencia causal

- **Problema fundamental:** nunca observamos a la misma unidad en los dos estados posibles ($D_i = 1$ y $D_i = 0$). Lo que efectivamente observamos es:

$$\begin{aligned} Y_i &= Y_i(1)D_i + Y_i(0)(1 - D_i) \\ &= Y_i(0) + (Y_i(1) - Y_i(0))D_i \\ &= Y_i(0) + \tau_i D_i. \end{aligned}$$

- Definamos:
 - $\tau \equiv \mathbb{E}[\tau_i \mid D_i = 1]$ (ATT: efecto promedio sobre los tratados).
 - $\alpha \equiv \mathbb{E}[Y_i(0)]$ (promedio poblacional de $Y_i(0)$).

Modelo de regresión lineal y sesgo de selección

- Considere el modelo de regresión:

$$Y_i = \alpha + \tau D_i + e_i; \quad \text{donde} \quad e_i \equiv \left((\tau_i - \tau) D_i + Y_i(0) - \alpha \right).$$

A partir de este modelo se obtiene:

$$\mathbb{E}[Y_i | D_i = 1] - \mathbb{E}[Y_i | D_i = 0] = \tau + \underbrace{\mathbb{E}[Y_i(0) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0]}_{\text{Sesgo de selección}}$$

- El estimador por MCO es:

$$\hat{\tau}_{mco} = \frac{\sum_i Y_i D_i}{N_1} - \frac{\sum_i Y_i (1 - D_i)}{N_0} \xrightarrow{p} \mathbb{E}[Y_i | D_i = 1] - \mathbb{E}[Y_i | D_i = 0]$$

donde $N_1 = \sum_i D_i$ y $N_0 = \sum_i (1 - D_i)$.

En otras palabras, $\hat{\tau}_{mco}$ estima la **diferencia observada de medias**, la cual solo coincide con el **ATT** cuando no existe sesgo de selección.

Aleatorización

Aleatorización como respuesta al problema de selección

Athey and Imbens (2017)

*“Definimos los **experimentos aleatorizados** como aquellos contextos en los que el **mecanismo de asignación** no depende de las características de las unidades, sean observadas o no observadas, y en los que **el investigador tiene control sobre dicha asignación.**”*

- Si asignamos a los individuos al grupo de tratamiento o control de manera **aleatoria**, entonces:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i.$$

La **aleatorización** garantiza que:

$$\mathbb{E}[Y_i(0)|D_i = 1] = \mathbb{E}[Y_i(0)|D_i = 0] = \mathbb{E}[Y_i(0)].$$


- Si se cumple SUTVA, $\hat{\tau}_{mco} \xrightarrow{p} \tau$, por lo que obtenemos un estimador consistente del **ATT**.

Aleatorización simple

Random sampling



Random assignment



Fuente: adaptado de [Scribbr](#)

Aleatorización por grupos (cluster randomization)

- En algunos contextos no es factible asignar el tratamiento de manera individual. En su lugar, se asigna **aleatoriamente a nivel de grupo o clúster** (p.ej., escuela, municipio).
- **Método de asignación:** el tratamiento se asigna a nivel de clúster, $D_c \in \{0, 1\}$, y todas las unidades del clúster lo heredan (**full compliance**):

$$D_i = D_c \quad \text{para todo } i \text{ en el clúster } c;$$

$$Y_{ic}(0), Y_{ic}(1) \perp\!\!\!\perp D_c.$$

- **Modelo de regresión:**

$$Y_{ic} = \alpha + \tau D_c + u_{ic}; \quad u_{ic} = \eta_c + e_{ic},$$

con η_c componente común al clúster y e_{ic} idiosincrático.

La aleatorización elimina el problema de selección, **pero la inferencia debe corregirse por la correlación intra-clúster.**

Aleatorización condicional (estratificada)

- En algunos experimentos, la asignación se realiza **dentro de grupos definidos por una característica** X_i (p.ej., género, educación, municipio). Esto implica que:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i | X_i; \quad y$$


$$\mathbb{E}[Y_i(0) | D_i = 1, X_i] = \mathbb{E}[Y_i(0) | D_i = 0, X_i] = \mathbb{E}[Y_i(0) | X_i].$$

- **Modelo de regresión:**

$$Y_i = \alpha + \tau D_i + \sum_x \delta_x \mathbf{1}\{X_i = x\} + u_i,$$

donde τ mide el efecto promedio del tratamiento controlando por diferencias entre estratos definidos por X_i .

Visualización de los esquemas de aleatorización



Esquemas de aleatorización: pros y contras

Simple

- + Fácil de implementar y analizar (diferencia de medias).
- + No requiere información previa.
- Posible desbalance en covariables por azar, sobre todo en muestras pequeñas.

Por clúster

- + Adecuado cuando el tratamiento opera a nivel de grupo.
- + Contiene los spillovers dentro del clúster: no contaminan al grupo de control.
- Menor potencia: por la correlación intra-clúster (ICC), el tamaño efectivo depende del número de clústeres.

Por estratos

- + Garantiza balance en las covariables de estratificación.
- + Mayor precisión si los estratos predicen Y.
- Requiere información previa para definir estratos.
- El análisis debe respetar el diseño (efectos fijos de estrato).

SUTVA

Valor estable de la unidad de tratamiento (SUTVA)

- **Supuesto adicional** (SUTVA): El resultado potencial de una unidad depende solo de su propio estado de tratamiento, no del de otras unidades ni de la forma de asignación.

1. **No interferencia**: sin spillovers, externalidades ni efectos de equilibrio general.

$$Y_i(D_i, \mathbf{D}_{-i}) = Y_i(D_i) \quad (\text{resultados potenciales})$$

donde $\mathbf{D}_{-i}$ denota el vector de asignaciones de **todas las demás unidades**.

2. **Consistencia/sin versiones múltiples**: el resultado bajo tratamiento es único, independientemente de cómo se reciba.
 - Diferente dosis.
 - Diferente percepción o recepción.
 - Contexto de aplicación.

Ejemplo de violación de SUTVA

- Sea $D_i \in \{0, 1\}$ un indicador de si el individuo i recibe tratamiento, y $Z_i \in \{0, 1\}$ un indicador de si *algún miembro del hogar* recibe tratamiento. D_i se asigna de manera aleatoria.
- **Problema:** $Y_i(D_i, Z_i) \neq Y_i(D_i)$. Por ejemplo, considere

$$Y_i(D_i, Z_i) = \begin{cases} Y_i(1) & \text{si } D_i = 1 \\ Y_i(0) & \text{si } D_i = 0 \text{ y } Z_i = 0 \\ Y_i(0) + \gamma & \text{si } D_i = 0 \text{ y } Z_i = 1 \end{cases}$$

con $\gamma > 0$.

- Si estimamos el modelo: $Y_i = \alpha + \tau D_i + e_i$ por MCO,

$$\begin{aligned} \hat{\tau}_{mco} &\xrightarrow{p} \mathbb{E}[Y_i(1) \mid D_i = 1] - \mathbb{E}[Y_i(0) + \gamma Z_i \mid D_i = 0] \\ &= \tau - \underbrace{\gamma \Pr[Z_i = 1 \mid D_i = 0]}_{\text{sesgo por spillover}}. \end{aligned}$$

Ejemplo: Miguel and Kremer (2004)


- Programa de desparasitación de niños en Kenia.
- **Problema:** si se aleatoriza al nivel de los niños y se ignoran los **efectos de contagio**, se **subestima** el verdadero impacto del programa.
- **Diseño:** se aleatorizaron los colegios que recibían el tratamiento (*cluster randomization*).
- **Resultados:**
 - Reducción significativa del ausentismo, especialmente entre los más jóvenes.
 - Efectos indirectos: estudiantes de colegios vecinos también se beneficiaron.
 - Al internalizar estas externalidades, el análisis costo-beneficio muestra que es socialmente rentable subsidiar la desparasitación.
- Es clave diseñar la aleatorización para **minimizar la interferencia entre unidades**.

Experimentos y cambios de comportamiento

- Aún con **asignación aleatoria**, los resultados potenciales pueden verse afectados por el hecho de participar en un experimento.
- **Efecto placebo**: un sujeto recibe una sustancia inerte, pero experimenta cambios por un estímulo psicológico.
- **Efecto Hawthorne**: los tratados modifican su conducta porque saben que están siendo observados.
 - Ejemplo clásico: experimentos en la *Western Electric Factory* sobre iluminación y productividad.
 - La productividad aumentaba durante los experimentos, pero caía al terminar la observación.

Experimentos y cambios de comportamiento

- **Efecto John Henry:** los no tratados cambian su conducta para compensar el no recibir tratamiento. Nombrado por la figura (legendaria) de John Henry en la industria del acero.
- **Experimenter demand effect:** los participantes ajustan su comportamiento según lo que creen que los investigadores esperan de ellos (p.ej., en actitudes frente a normas sociales).
- Estos efectos pueden darse en otros contextos, pero son especialmente relevantes en evaluaciones experimentales: los individuos saben que forman parte de un estudio.



"So I'm guessing we're in the placebo group."

Autor: Paul Noth (Alta Journal (2023)).

- Bajo los supuestos:
 1. **Asignación aleatoria** del tratamiento.
 2. **SUTVA** (sin interferencias, consistencia).


$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0] = \tau.$$

El **poder de los RCTs** es que, con estos supuestos, el problema de identificación queda resuelto.

- La **estimación es directa**:
 1. Mediante la **diferencia de medias** entre grupos.
 2. Modelo de regresión estimado por MCO.

Validez interna y externa

- **Validez interna:** capacidad de atribuir causalidad al efecto estimado *dentro de la muestra del estudio*.
- **Validez externa:** grado en que los resultados pueden *generalizarse y replicarse* en otras poblaciones o contextos.



Fuente: Gertler et al. (2010).

Verificación de la aleatorización

Verificación de la aleatorización

- Si hay una **asignación aleatoria**, D_i no debe estar correlacionada con ninguna variable observada (predeterminada).

$$D_i = \mathbf{X}_i' \boldsymbol{\gamma} + \eta_i.$$

Si las variables en $\mathbf{X}_i$ son predeterminadas respecto al tratamiento, o no están afectadas por este, no deberíamos rechazar la hipótesis nula en pruebas de significancia individual (o conjunta):

$$\mathbb{H}_0 : \gamma_k = 0,$$

$$\mathbb{H}_1 : \gamma_k \neq 0.$$

De forma alternativa, si hacemos una prueba estadística de **diferencia de medias** entre tratados y no tratados para cada variable en $\mathbf{X}$, no deberíamos ver diferencias significativas.

	Front Street ITT Status ($b_{p,0}^Z$)				
	(1)	(2)	(3)	(4)	(5)
	ITT=1	ITT=0	Diff.	P-value	Norm. Diff
Plot-Level Administrative Data					
Tax Compliance (0-1)	0.855 (0.353)	0.846 (0.361)	0.008 (0.038)	0.830	0.016
Cadastral Property Value (USD)	36,492.395 (39,254.489)	42,158.541 (45,788.269)	-5,666.146 (6,231.454)	0.367	-0.064
Tax Liability (USD)	35.685 (14.406)	36.720 (15.231)	-1.035 (1.518)	0.499	-0.050
Plot-Level ASLS Data					
Dissatisfied with the Local Government (0-1)	0.545 (0.498)	0.530 (0.499)	0.015 (0.053)	0.771	0.038
Dissatisfied with Living in Acayucan (0-1)	0.142 (0.350)	0.139 (0.346)	0.003 (0.031)	0.912	0.041
Log of Self-Reported Property Value (USD)	11.757 (0.977)	11.844 (0.954)	-0.086 (0.138)	0.534	-0.008
Travel Time to the City Center (Minutes)	19.699 (10.563)	20.442 (12.047)	-0.743 (1.228)	0.548	-0.040
Per Capita Expenditure (USD)	201.899 (154.370)	191.201 (159.535)	10.698 (21.862)	0.626	0.058
Plot-Level Property Appraisals					
Log of Property Appraised Value (USD)	11.575 (0.650)	11.633 (0.796)	-0.058 (0.099)	0.557	-0.034
Log of Land Appraised Value (USD)	10.272 (0.608)	10.139 (0.499)	0.133 (0.103)	0.199	0.167
Project-Level OpenStreetMap Data ($n = 47$ projects)					
Street Length (Meters)	376.568 (149.511)	557.747 (507.345)	-181.180 (103.427)	0.087	-0.484
Katz Centrality	0.0169 (0.0009)	0.0168 (0.0008)	0.0001 (0.0002)	0.631	0.143
Distance to City Center (Meters)	1,650.817 (487.314)	1,712.598 (496.719)	-61.780 (144.818)	0.672	-0.125

	Control group			Treatment – control	
	Obs. (1)	Mean (2)	SD (3)	Coeff. (4)	p-value (5)
<i>Household composition</i>					
Number members	1,220	5.038	(1.666)	0.095	0.303
Number adults (>=16 years old)	1,220	3.439	(1.466)	-0.011	0.873
Number children (<16 years old)	1,220	1.599	(1.228)	0.104	0.098
Male head	1,216	0.907	(0.290)	-0.012	0.381
Head's age	1,216	41.150	(10.839)	-0.243	0.676
Head with no education	1,216	0.370	(0.483)	-0.008	0.787
<i>Access to credit</i>					
Loan from Spandana	1,213	0.000	(0.000)	0.007	0.195
Loan from other MFI	1,213	0.011	(0.103)	0.007	0.453
Loan from a bank	1,213	0.036	(0.187)	0.001	0.859
Informal loan	1,213	0.632	(0.482)	0.002	0.958
Any type of loan	1,213	0.680	(0.467)	0.002	0.942
<i>Amount borrowed from (in Rs)</i>					
Spandana	1,213	0	(0.000)	69	0.192
Other MFI	1,213	201	(2,742)	170	0.568
Bank	1,213	7,438	(173,268)	-5,420	0.279
Informal loan	1,213	28,460	(65,312)	-570	0.856
Total	1,213	37,892	(191,292)	-5,879	0.343
<i>Self-employment activities</i>					
Number of activities	1,220	0.320	(0.682)	-0.019	0.579
Number of activities managed by women	1,220	0.145	(0.400)	-0.007	0.750
Share of HH activities managed by women	295	0.488	(0.482)	-0.006	0.904
<i>Businesses</i>					
Revenue/month (Rs)	295	15,991	(53,489)	4,501	0.539
Expenses/month (Rs)	295	3,617	(26,144)	641	0.751
Investment/month (Rs)	295	385	(3,157)	14	0.959
Employment (employees)	295	0.169	(0.828)	0.255	0.148
Self-employment (hours per week)	295	76.315	(66.054)	-4.587	0.414
<i>Businesses (all households)</i>					
Revenue/month (Rs)	1,220	3,867	(27,147)	904	0.626
Expenses/month (Rs)	1,220	875	(12,933)	116	0.812
Investment/month (Rs)	1,220	93	(1,559)	-0.098	0.999
Employment (employees)	1,220	0.041	(0.413)	0.057	0.166
Self-employment (hours per week)	1,220	18.453	(46.054)	-1.801	0.400
<i>Consumption (per household per month)</i>					
Total consumption (Rs)	1,220	4,888	(4,074)	270	0.232
Nondurables consumption (Rs)	1,220	4,735	(3,840)	252	0.235
Durables consumption (Rs)	1,220	154	(585)	18	0.531
Asset index	1,220	1.941	(0.829)	0.027	0.669

Controles en RCTs: ¿por qué incluirlos?

- Podemos incluir **covariables predeterminadas** (no afectadas por el tratamiento) en:

$$Y_i = \alpha + \tau D_i + \mathbf{X}_i' \boldsymbol{\gamma} + e_i$$

- Con asignación aleatoria ($D_i \perp\!\!\!\perp \mathbf{X}_i$), la consistencia del estimador de τ no depende de incluir controles. Sin embargo,
 - **Mejora la precisión** $\Rightarrow$ si $\mathbf{X}$ predice Y , el error tiene menor varianza que en el modelo sin controles ($Y_i = \alpha + \tau D_i + u_i$):

$$\text{Var}[e_i] \leq \text{Var}[u_i]$$

- Mitiga **desequilibrios muestrales** que ocurren por azar.
- Permite **respetar el diseño**: por ejemplo, incluir efectos fijos de estrato.

Buenas prácticas al incluir controles

■ Qué incluir:

- Valor de línea de base de Y : el mejor predictor; grandes ganancias de potencia (McKenzie, 2012).
- Covariables predeterminadas que predicen Y y efectos fijos de estrato (si aplica).
- Interacciones $D_i \times (X_i - \bar{X})$ para heterogeneidad.

■ Qué evitar:

- Variables post-tratamiento o mediadores: “malos controles” que sesgan τ .
- Muchos controles poco predictivos: el ajuste puede sesgar en muestras pequeñas (Freedman, 2008).

Inferencia por aleatorización

Tipos de incertidumbre

- **Inferencia basada en el muestreo:** Los estimadores y estadísticos son aleatorios porque los datos provienen de una muestra aleatoria. Por ejemplo:

$$T_N = T(\mathbf{Y}, \mathbf{D})$$

donde $\{(Y_i, D_i) : i = 1, \dots, N\}$ son observaciones extraídas de la población y $D_i \in \{0, 1\}$.

- **Inferencia por aleatorización:** Los *resultados potenciales* $Y(0), Y(1)$ se consideran fijos, y la fuente de aleatoriedad es la asignación al tratamiento:

$$T(D) = T(\mathbf{D} \mid \mathbf{Y}(0), \mathbf{Y}(1)).$$

Para simplificar, tratamos la muestra como si fuera la población completa:

N : total de unidades, N_1 : tratadas, N_0 : control, $N = N_1 + N_0$.

Idea básica de la inferencia por aleatorización

- Sea $\mathbf{D}^{\text{obs}} = (D_1, \dots, D_N)'$ el vector de asignaciones observado y considere la hipótesis:

$$\mathbb{H}_0 : Y_i(0) = Y_i(1), \quad \forall i = 1, \dots, N.$$

$$\mathbb{H}_1 : Y_i(0) \neq Y_i(1), \quad \text{para al menos un } i.$$

Definamos el estadístico:

$$T(D^{\text{obs}}) = \frac{1}{N_1} \sum_i Y_i D_i - \frac{1}{N_0} \sum_i Y_i (1 - D_i).$$

La diferencia de medias calculada con la asignación $\mathbf{D}^{\text{obs}}$.

- En un diseño completamente aleatorizado, todas las asignaciones con N_1 tratados son equiprobables:

$$\Pr[\mathbf{D} \mid \mathbf{Y}(0), \mathbf{Y}(1)] = \binom{N}{N_1}^{-1} \quad \forall \mathbf{D} \text{ con } \sum_i D_i = N_1.$$

Permutaciones (aleatorización simple)

- Bajo $\mathbb{H}_0$, $Y_i(1) = Y_i(0)$ y, por tanto, $\mathbf{Y}$ no depende de $\mathbf{D}$. Las variaciones de T provienen solo del azar de la asignación.
- **Algoritmo:**
 1. Generar J reasignaciones $\mathbf{D}^{(j)}$ que **respeten el diseño** (mismo N_1 ; dentro de estratos o por clúster si aplica).

2. Calcular

$$T(D^{(j)}) = \frac{1}{N_1} \sum_i Y_i D_i^{(j)} - \frac{1}{N_0} \sum_i Y_i (1 - D_i^{(j)}).$$

3. Estimar el p -valor:

$$p\text{-val} = \frac{1}{J} \sum_{j=1}^J \mathbf{1}\{|T(D^{(j)})| \geq |T(D^{\text{obs}})|\}.$$

Si el p -val es menor al nivel de significancia deseado, la evidencia no es consistente con $\mathbb{H}_0$.

Extensiones de la inferencia por aleatorización

- **Uso de covariables:** podemos construir estadísticos que ajusten por variables X (por ejemplo, regresión de Y_i en D_i y X_i). La regla de permutación *no cambia*: siempre debe respetar el diseño original.
- **Diseños más complejos:** si la asignación fue por *estratos* o *clústeres*, las permutaciones se realizan dentro de esas mismas estructuras.
- **Otros estadísticos:** además de medias, se pueden usar medianas, rangos o pruebas de distribución.
- **Interferencia o spillovers:** si el tratamiento de una unidad afecta a otras, se pueden plantear hipótesis basadas en *exposición* o en redes.

No todo es perfecto

- Algunas críticas a los RCTs (Deaton and Cartwright, 2018):
 1. El **alcance de las preguntas**: los RCTs solo permiten responder un subconjunto limitado de las preguntas relevantes en economía.
 2. **Validez externa**: la evidencia enfrenta las mismas limitaciones de extrapolación y generalización que otros métodos.
 - Dificultades para “escalar” intervenciones probadas en entornos controlados.
 3. **Problemas de atrición y selección**: la pérdida de participantes o el sesgo en quién permanece en tratamiento/control pueden afectar los resultados.

¿Qué estamos estimando?

- ¿Qué mide exactamente el efecto causal?

$$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)].$$

Este es un **efecto total**, no una **derivada parcial** (Duflo et al., 2007).

- Supongamos que la variable de resultado se determina como:

$$Y = f(Z, D, e; \theta).$$

La asignación al tratamiento puede afectar tanto a Y como a Z .
¿Cuáles son los **mecanismos** que generan el efecto observado?

- Para responder, necesitamos un modelo que haga explícitas las relaciones entre variables. Es decir, se requiere **combinar con teoría** (Keane, 2010; Andrews et al., 2023).