

Econometría Avanzada

Estimadores de Matching y Reponderación

Manuel Fernández

16 de septiembre de 2026

Temas de la clase:

1. Independencia condicional
2. Propensity Score Matching (PSM)
 - Emparejamiento y propensity score
 - Soporte común
 - Algoritmos de emparejamiento
3. Modelo de regresión lineal
4. Inverse Probability Weighting (IPW)
5. Anexo

Independencia condicional

Selección en estudios observacionales

- Si la asignación al tratamiento $D_i \in \{0, 1\}$ **no es aleatoria**, el grupo de control puede no representar un contrafactual válido para los tratados:

$$\underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1]}_{\text{Contrafactual}} \neq \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{Estimable con el grupo de control}} .$$

Esto ocurre, por ejemplo, cuando las personas **se autoseleccionan** en el tratamiento.

- Suponga que la selección depende únicamente de factores **observables** X_i , tal que:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid X_i.$$

Esta condición se conoce como **independencia condicional** o **ignorabilidad**: condicionar en X_i hace que la asignación sea “como si” fuera aleatoria.

Identificación del efecto causal bajo independencia condicional

- Defina el **efecto causal promedio condicional (CATE)**:

$$\tau(\mathbf{x}) \equiv \mathbb{E}[Y_i(1) - Y_i(0) \mid \mathbf{X}_i = \mathbf{x}].$$

Si se cumple la **independencia condicional**, la **diferencia de medias condicional** identifica el **CATE**:

$$\begin{aligned}\mathbb{E}[Y_i | \mathbf{X}_i, D_i = 1] - \mathbb{E}[Y_i | \mathbf{X}_i, D_i = 0] &= \mathbb{E}[Y_i(1) | \mathbf{X}_i, D_i = 1] - \mathbb{E}[Y_i(0) | \mathbf{X}_i, D_i = 0] \\ &= \mathbb{E}[Y_i(1) | \mathbf{X}_i] - \mathbb{E}[Y_i(0) | \mathbf{X}_i] \\ &= \tau(\mathbf{X}_i).\end{aligned}$$

- El efecto promedio en la población (**ATE** o **ATT**) es

$$\tau_{ATE} = \mathbb{E}[\tau(\mathbf{X}_i)] \quad \text{y} \quad \tau_{ATT} = \mathbb{E}[\tau(\mathbf{X}_i) | D_i = 1],$$

donde promediamos sobre la distribución de $\mathbf{X}_i$ en la población de interés.

1. ¿Cuándo es plausible suponer **independencia condicional**?
2. ¿Cómo estimar la diferencia de medias condicional y el **ATE** o **ATT**?

Propensity Score Matching (PSM)

Propensity Score Matching (PSM): Intuición

- Imagine una situación **hipotética** en la que, para cada unidad i tratada ($D_i = 1$), existiera un “**clon**” j : una unidad idéntica en todas las características *relevantes* (**observadas y no observadas**), pero que no recibe el tratamiento ($D_j = 0$).
- En ese caso, podríamos comparar los resultados de i y su **clon** j para estimar el efecto del tratamiento:

$$\tau_i = Y_i(1) - Y_i(0) \approx Y_i(1) - Y_j(0) = Y_i - Y_j.$$

Si i tuviera varios posibles **clones** (conjunto $\mathcal{C}(i)$), usaríamos el **promedio** de sus resultados como contrafactual:

$$\tau_i \approx Y_i - \mathbb{E}[Y_j | j \in \mathcal{C}(i)].$$

- Los métodos de **matching**, y **PSM** en particular, siguen esta intuición.

¿Cómo definir un clon en la práctica?

- Para cada unidad contamos con un conjunto de **características observables predeterminadas**, resumidas en el vector $\mathbf{X}_i$.
- La idea es **emparejar** cada tratado con una o varias unidades en el grupo de control que tengan valores similares de $\mathbf{X}_i$.
- **Dificultades en la práctica:**
 1. Sólo observamos un **conjunto limitado de covariables**: podemos emparejar en lo que está medido, pero no en factores no observados que también pueden influir.
 2. Es posible que no exista ninguna unidad en el grupo de control con los mismos valores exactos de $\mathbf{X}_i$.

Supuesto de independencia condicional

- El supuesto de **independencia condicional** establece que, una vez que emparejamos unidades de tratamiento y de control con el mismo vector de covariables X_i , la asignación al tratamiento es **como si fuera aleatoria**.
- En este caso, el conjunto $\mathcal{C}(i)$ se define por los valores de X_i y permite aproximar el contrafactual no observado.

Implicaciones del supuesto

Este supuesto es **muy exigente**: requiere que **todos los factores** que influyen tanto en la probabilidad de recibir el tratamiento como en el resultado sean observables. $\Rightarrow$ No debe existir **sesgo de selección por variables no observadas**.

Emparejamiento no paramétrico

- Una solución natural es agrupar las unidades en la muestra en **celdas** según los valores de $\mathbf{X}_i$ y comparar tratados y controles dentro de cada celda.
- **Problema: maldición de la dimensionalidad**
 - Con k variables binarias hay 2^k posibles celdas.
 - Muchas celdas quedan con muy pocas observaciones (o ninguna) $\Rightarrow$ **estimaciones ruidosas**.
 - Algunas celdas pueden contener sólo tratados o sólo controles, impidiendo la comparación.

Emparejamiento por propensity score

- **Alternativa:** resumir el vector de covariables $\mathbf{X}_i$ en un **único escalar** y emparejar las unidades usando ese escalar y una **medida de distancia**.
- Ese escalar es el **propensity score**:

$$p(\mathbf{x}) \equiv \Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}], \quad p_i \equiv p(\mathbf{X}_i).$$

Teorema del propensity score (Rosenbaum and Rubin, 1983)

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid \mathbf{X}_i \implies Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid p_i.$$

Intuición: bajo **independencia condicional**, basta con condicionar en p_i en lugar de todo $\mathbf{X}_i$. [◀ Demostración](#)

- Pregunta práctica: ¿cómo estimar p_i ?

Soporte común

- Para identificar efectos causales mediante *matching*, cada unidad tratada debe tener al menos un **control comparable**.
- En términos del **propensity score**, esto requiere que


$$0 < \Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] < 1.$$

- Si $\Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] = 1$: sólo hay tratados con esas características $\mathbf{x}$, sin controles comparables.
 - Si $\Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] = 0$: sólo hay controles con esas características $\mathbf{x}$, sin tratados comparables.
 - En ambos casos, **no existe soporte común**.
- Cuando se cumplen simultáneamente el supuesto de **independencia condicional** y el de **soporte común**, hablamos de **ignorabilidad fuerte**.

Restricción al soporte común en la muestra

- Debemos restringir la muestra de estimación a la región de **soporte común** ($\mathcal{S}$):

$$\mathcal{S} = \left[\max\left\{ \min_{\{i:D_i=1\}} \hat{p}_i, \min_{\{i:D_i=0\}} \hat{p}_i \right\}, \min\left\{ \max_{\{i:D_i=1\}} \hat{p}_i, \max_{\{i:D_i=0\}} \hat{p}_i \right\} \right].$$



- **Implicación:** los efectos causales sólo son válidos para las unidades que pertenecen al **soporte común**.

Resumiendo: pasos para aplicar PSM

- El teorema del **propensity score** sugiere un procedimiento en cuatro pasos:
 1. **Estimar** el **propensity score** $\hat{p}_i$ para cada unidad (e.g., *logit*, *probit*).
 2. **Restringir** la muestra a la región de **soporte común**: $\{i: \hat{p}_i \in \mathcal{S}\}$.
 3. **Emparejar** tratados y controles con valores similares de $\hat{p}_i$.
 4. **Estimar** el efecto: comparar resultados entre unidades emparejadas y promediar para obtener el **efecto promedio del tratamiento**.

Algoritmos de emparejamiento: fórmula general

- **Estimando** (e.g., ATT en soporte común):

$$\begin{aligned}\tau_{ATT} &= \mathbb{E} \left[\mathbb{E}[Y_i \mid D_i = 1, p_i] - \mathbb{E}[Y_i \mid D_i = 0, p_i] \mid D_i = 1, p_i \in \mathcal{S} \right] \\ &= \mathbb{E} \left[\tau(p_i) \mid D_i = 1, p_i \in \mathcal{S} \right] \quad \text{donde} \quad p_i \equiv \Pr[D_i = 1 \mid \mathbf{X}_i].\end{aligned}$$

- **Estimador**: con una muestra de N_1 tratados en el soporte común,

$$\hat{\tau}_{ATT} = \frac{1}{N_1} \sum_{\{i: D_i=1, \hat{p}_i \in \mathcal{S}\}} \left(Y_i - \sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} \omega(i, j) Y_j \right),$$

donde:

- $\omega(i, j)$: peso asignado al control j al construir el contrafactual de la unidad tratada i , con $\sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} \omega(i, j) = 1$ para cada i .

Algoritmos de emparejamiento: Vecino más cercano

- Cada unidad tratada i se empareja con la unidad de control j cuyo **propensity score estimado** sea el más cercano al de i :

$$j(i) = \arg \min_{\{k: D_k=0, \hat{p}_k \in \mathcal{S}\}} |\hat{p}_i - \hat{p}_k|, \quad \omega(i, j) = \mathbf{1}\{j = j(i)\}.$$

En este caso, $\omega(i, j)$ toma el valor de uno para el vecino más cercano y cero de lo contrario.

- En la práctica, nada garantiza que el **vecino más cercano** sea efectivamente “cercano”. Es fundamental verificar el **balance** en las covariables $\mathbf{X}$ entre los grupos de tratamiento y control después del emparejamiento.

Vecino más cercano: Algunas consideraciones

1. **Con reemplazo:** varias unidades tratadas pueden ser emparejadas a la misma unidad en el grupo de control.
2. **Sin reemplazo:** si la unidad en el grupo de control fue emparejada, no se usa más $\implies$ ¡El orden del emparejamiento importa!
 - Una extensión natural es usar los M **vecinos más cercanos**, asignando un peso respectivo $\frac{1}{M}$ a cada uno.

Algoritmos de emparejamiento: Distancia máxima

- **Distancia máxima (radio):** cada unidad tratada i se empareja con las unidades de control cuyo **propensity score** esté a una distancia máxima q . Definimos

$$L(i, j) = \mathbf{1}\{|\hat{p}_i - \hat{p}_j| \leq q\},$$

y asignamos el peso

$$\omega(i, j) = \begin{cases} \frac{1}{\sum_{\{k: D_R=0, \hat{p}_R \in \mathcal{S}\}} L(i, k)} & \text{si } L(i, j) = 1 \\ 0 & \text{si } L(i, j) = 0. \end{cases}$$

Si ningún control está a distancia q de i , la unidad tratada se descarta (cambia el estimando).

- En la versión **caliper** de distancia máxima, se usan únicamente los M vecinos más cercanos, condicional a estar a una distancia máxima q .

Algoritmos de emparejamiento: Kernel

- **Emparejamiento usando función de Kernel:** Asigna mayor peso a las unidades de control más **cercanas** y menor peso a las más **lejanas**, según la distancia en el **propensity score estimado**.
- El contrafactual predicho para cada unidad i es:


$$\hat{Y}_i(0) = \frac{\sum_{\{j:D_j=0, \hat{p}_j \in \mathcal{S}\}} K\left(\frac{\hat{p}_i - \hat{p}_j}{h}\right) Y_j}{\sum_{\{j:D_j=0, \hat{p}_j \in \mathcal{S}\}} K\left(\frac{\hat{p}_i - \hat{p}_j}{h}\right)},$$

donde $K(\cdot)$ es la **función Kernel** y h es el **ancho de banda**.

- **Estimador:**

$$\hat{\tau}_{ATT} = \frac{1}{N_1} \sum_{\{j:D_j=1, \hat{p}_j \in \mathcal{S}\}} \left(Y_j - \hat{Y}_j(0) \right).$$

Funciones de Kernel



Por ejemplo, si el Kernel es **Gaussiano**, los pesos decrecen siguiendo la distribución normal.

Errores estándar en PSM

- En PSM, los errores estándar deben reflejar tres fuentes de variación:
 - 1) **Estimación** del propensity score $\hat{p}_i$.
 - 2) **Restricción** al soporte común.
 - 3) **Algoritmo** de emparejamiento.

El uso de **bootstrapping** (Efron, 1979) es frecuente, pero **puede ser inconsistente** (Abadie and Imbens, 2008).

- **Alternativas:**
 - Usar fórmulas **analíticas de varianza** para matching (Abadie and Imbens, 2006, 2016).
 - En métodos “suaves” (kernel, radio): estimar varianzas con bootstrap, **re-estimando** $\hat{p}_i$ y rehaciendo *trimming* en cada réplica.

Modelo de regresión lineal

Aproximación a la CEF

- Suponga que, en ausencia de tratamiento, **modelamos**

$$\mathbb{E}[Y_i(0)|\mathbf{X}_i] = \mathbf{X}_i'\boldsymbol{\beta}.$$

Es una aproximación (proyección lineal), no sabemos la CEF “real”:

1. Imponemos una forma funcional que nos puede llevar a **errores de especificación**.
2. Si los soportes de $\mathbf{X}$ difieren entre tratados y controles, $\mathbf{X}_i'\boldsymbol{\beta}$ puede **extrapolar**.

- Bajo **independencia condicional** $Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid \mathbf{X}_i$:

$$\begin{aligned} Y_i &= Y_i(0) + \left(Y_i(1) - Y_i(0) \right) D_i \implies \mathbb{E}[Y_i|\mathbf{X}_i, D_i] = \tau(\mathbf{X}_i)D_i + \mathbb{E}[Y_i(0)|\mathbf{X}_i] \\ &\approx \tau(\mathbf{X}_i)D_i + \mathbf{X}_i'\boldsymbol{\beta}. \end{aligned}$$

donde $\tau(\mathbf{X}_i) \equiv \mathbb{E}[Y_i(1) - Y_i(0)|\mathbf{X}_i]$ son los **CATE**.

El modelo de regresión lineal

- Considere el modelo de regresión:

$$Y_i = \tau D_i + \mathbf{X}_i' \boldsymbol{\beta} + e_i. \quad (1)$$

¿Cómo se relacionan $\mathbb{E}[\tau(\mathbf{X}_i)]$ y τ ? ¿Qué está estimando MCO?

- Por el teorema de **Frisch–Waugh–Lovell** (FWL), estimar (1) por MCO es equivalente a estimar

$$\tilde{Y}_i = \tau \tilde{D}_i + \eta_i,$$

donde $\tilde{Y}_i$ y $\tilde{D}_i$ son los **residuales de la proyección lineal** de Y_i y D_i en $\mathbf{X}_i$, respectivamente.

¿Qué estima MCO en el modelo de regresión lineal?

- Bajo **ignorabilidad fuerte**, si p_i es lineal en los controles incluidos (p. ej., una especificación saturada), se puede  que:

$$\text{plim } \hat{\tau}_{mco} = \frac{\mathbb{E}[\tau(\mathbf{X}_i)\omega(\mathbf{X}_i)]}{\mathbb{E}[\omega(\mathbf{X}_i)]} \neq \mathbb{E}[\tau(\mathbf{X}_i)] \text{ (en general),}$$

donde $\omega(\mathbf{X}_i) \equiv \mathbb{E}[\tilde{D}_i^2 \mid \mathbf{X}_i] = p_i(1 - p_i)$.

- MCO estima un promedio ponderado de los **CATE**, con pesos proporcionales a la varianza condicional del tratamiento: **actúa como un estimador de *matching* con pesos específicos**.
- Si los efectos son **homogéneos**: $\tau(\mathbf{X}_i) = \tau \forall \mathbf{X}_i$, se cumple que $\text{plim } \hat{\tau}_{mco} = \mathbb{E}[\tau(\mathbf{X}_i)] = \tau$. De lo contrario, el efecto estimado puede diferir de los obtenidos con estimadores de *matching*.


Extrapolación si la CEF no es lineal

- **Error de especificación:** si p_i no es lineal en los controles incluidos, la fórmula anterior **no está garantizada** y puede haber sesgo por una forma funcional incorrecta.
- **Problema de extrapolación:** con **pobre overlap** entre tratados y controles, el contrafactual de algunos tratados se construye usando observaciones “lejanas” en el espacio de covariables.
- **Consecuencia:** aun bajo los supuestos anteriores, $\hat{\tau}_{mco}$ puede ser **inconsistente** para el ATE (o el ATT) por sus pesos sobre los CATE. El poco *overlap* puede reducir la precisión.

Forma funcional y extrapolación en MCO: una simulación


- Se cumple **independencia condicional**, pero **no** hay soporte común.

Una muestra ($N = 100$)



MCO impone rectas paralelas (**forma funcional**) y usa la recta azul donde no hay controles (**extrapolación**): $\hat{\tau}_{mco} \approx 3.5$.

5000 muestras: distribución de $\hat{\tau}_{mco}$



El sesgo es **sistemático**: $\hat{\tau}_{mco}$ se concentra alrededor de 3.5, no de $\tau = 0$. Más datos $\Rightarrow$ más precisión, **no** menos sesgo.

Angrist and Pischke (2011)

“We believe regression should be the starting point for most empirical projects. This is not a theorem; undoubtedly, there are circumstances where propensity score matching provides more reliable estimates of average causal effects. The first reason we don’t find ourselves on the propensity-score bandwagon is practical: there are many details to be filled in when implementing propensity-score matching – such as how to model the score and how to do inference – these details are not yet standardized. Different researchers might therefore reach very different conclusions, even when using the same data and covariates.”

Imbens (2015)

“Researchers continue to use ordinary linear regression methods with an indicator for the treatment and covariates entering additively and linearly. However, such simple methods do not always work well... the simple ordinary least squares estimator, which ultimately relies on the same fundamental unconfoundedness assumption as matching and propensity score estimators, but combines that assumption with strong functional form restrictions, is likely to be inadequate for estimating average treatment effects.”

Inverse Probability Weighting (IPW)

Inverse Probability Weighting (IPW)

- Suponga que se cumple **ignorabilidad fuerte**:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid \mathbf{X}_i, \quad p_i \equiv \Pr[D_i = 1 \mid \mathbf{X}_i] \in (0, 1),$$

entonces se cumple la siguiente **identidad** (Horvitz and Thompson, 1952):

$$\mathbb{E} \left[\frac{D_i Y_i}{p_i} \right] = \mathbb{E}[Y_i(1)], \quad \mathbb{E} \left[\frac{(1 - D_i) Y_i}{1 - p_i} \right] = \mathbb{E}[Y_i(0)].$$

◀ Demostración

$$\tau_{ATE} = \mathbb{E} \left[\frac{D_i Y_i}{p_i} - \frac{(1 - D_i) Y_i}{1 - p_i} \right].$$

- Esto motiva el **estimador IPW** en la práctica:

$$\hat{\tau}_{IPW} = \frac{1}{N} \sum_i \left(\frac{D_i Y_i}{\hat{p}_i} - \frac{(1 - D_i) Y_i}{1 - \hat{p}_i} \right).$$

IPW normalizado (Hájek)

- El estimador IPW de Horvitz and Thompson (1952) puede tener alta varianza porque los pesos

$$\omega_i(1) = \frac{D_i}{\hat{p}_i}, \quad \omega_i(0) = \frac{1 - D_i}{1 - \hat{p}_i},$$

no necesariamente suman N en la muestra (su valor esperado).

- IPW de Hájek (normalizado): reescala los pesos dentro de cada grupo,

$$\hat{\tau}_{\text{IPW}}^H = \frac{\sum_i \frac{D_i Y_i}{\hat{p}_i}}{\sum_i \frac{D_i}{\hat{p}_i}} - \frac{\sum_i \frac{(1-D_i) Y_i}{1-\hat{p}_i}}{\sum_i \frac{(1-D_i)}{1-\hat{p}_i}},$$

donde $\frac{1}{N} \sum_i \frac{D_i}{\hat{p}_i} \xrightarrow{p} 1$ y $\frac{1}{N} \sum_i \frac{1-D_i}{1-\hat{p}_i} \xrightarrow{p} 1$. Este estimador es **consistente** y suele tener menor varianza. También hace que el estimador se interprete como una media ponderada usual.


IPW: intuición no técnica

- Si tratados y controles difieren en sus covariables X , un *promedio directo* compara **manzanas con peras**.
- El **IPW repondera** las observaciones según su *propensity score*:
 - Más peso a las unidades **raras** (con baja probabilidad de estar en su grupo).
 - Menos peso a las unidades **comunes**.

De esta forma, la muestra ponderada queda **balanceada**: tratados y controles terminan con distribuciones comparables de X .


- El promedio ponderado elimina el sesgo de composición y aproxima el **efecto causal promedio**.

IPW balancea el propensity score



- **Sin ajuste:** las distribuciones de $\hat{p}_i$ de tratados y controles son muy distintas.
- **Con IPW:** al ponderar cada grupo por sus pesos, ambas distribuciones se aproximan a la de la **población**.

IPW balancea las covariables



Nota: misma simulación anterior. $SMD = (\bar{x}_T - \bar{x}_C) / \sqrt{(s_T^2 + s_C^2)/2}$, con desviaciones de la muestra sin ajustar.

- El propensity score es un **balancing score**: igualar su distribución equilibra **todas** las covariables, incluidas transformaciones e interacciones.
- En la práctica: **reportar el balance** antes y después de ponderar.

Anexo

Demostración: teorema del propensity score (I)

- Como D_i es **binaria**, su distribución condicional está determinada por su media. Basta entonces demostrar que

$$\begin{aligned}\mathbb{E}[D_i \mid Y_i(0), Y_i(1), p_i] &= \Pr[D_i = 1 \mid Y_i(0), Y_i(1), p_i] \\ &= \Pr[D_i = 1 \mid p_i] \\ &= \mathbb{E}[D_i \mid p_i].\end{aligned}$$

es decir, que condicional en p_i , la asignación no depende de $(Y_i(0), Y_i(1))$.

- Por la **ley de expectativas iteradas** (condicionando primero en $\mathbf{X}_i$, que determina p_i):

$$\mathbb{E}[D_i \mid Y_i(0), Y_i(1), p_i] = \mathbb{E} \left[\mathbb{E}[D_i \mid Y_i(0), Y_i(1), \mathbf{X}_i] \mid Y_i(0), Y_i(1), p_i \right].$$

Demostración: teorema del propensity score (II)

- Bajo **independencia condicional**, $\mathbb{E}[D_i \mid Y_i(0), Y_i(1), \mathbf{x}_i] = \mathbb{E}[D_i \mid \mathbf{x}_i]$, donde $\mathbb{E}[D_i \mid \mathbf{x}_i] = p_i$. Por consiguiente

$$\mathbb{E}[D_i \mid Y_i(0), Y_i(1), p_i] = \mathbb{E}[p_i \mid Y_i(0), Y_i(1), p_i] = p_i.$$

- De forma análoga, por la **ley de expectativas iteradas**:

$$\mathbb{E}[D_i \mid p_i] = \mathbb{E}[\mathbb{E}[D_i \mid \mathbf{x}_i] \mid p_i] = \mathbb{E}[p_i \mid p_i] = p_i.$$

- Se desprende que

$$\mathbb{E}[D_i \mid Y_i(0), Y_i(1), p_i] = \mathbb{E}[D_i \mid p_i],$$

y podemos concluir que $Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid p_i$.

Demostración: $\text{plim } \hat{\tau}_{mco}$ (I)

- Por **FWL**, con $\tilde{D}_i$ y $\tilde{Y}_i$ los residuales de la **proyección lineal** en $\mathbf{X}_i$ (incluida la constante):

$$\text{plim } \hat{\tau}_{mco} = \frac{\mathbb{E}[\tilde{D}_i \tilde{Y}_i]}{\mathbb{E}[\tilde{D}_i^2]}.$$

- **Supuesto:** $p_i \equiv \mathbb{E}[D_i | \mathbf{X}_i]$ es lineal en $\mathbf{X}_i$. Así, $\tilde{D}_i = D_i - p_i$ y $\mathbb{E}[\tilde{D}_i | \mathbf{X}_i] = 0$.
- Usando resultados potenciales: $Y_i = Y_i(0) + D_i \tau_i$, donde $\tau_i \equiv Y_i(1) - Y_i(0)$. Entonces:

$$\mathbb{E}[\tilde{D}_i Y_i | \mathbf{X}_i] = \underbrace{\mathbb{E}[(D_i - p_i) Y_i(0) | \mathbf{X}_i]}_{\text{Término A}} + \underbrace{\mathbb{E}[(D_i - p_i) D_i \tau_i | \mathbf{X}_i]}_{\text{Término B}}.$$

Demostración: $\text{plim } \hat{\tau}_{mco}$ (II)

- **Término A:** bajo **ignorabilidad**, $Y_i(0) \perp\!\!\!\perp D_i \mid \mathbf{X}_i$, por lo que

$$\mathbb{E}[(D_i - p_i)Y_i(0) \mid \mathbf{X}_i] = \mathbb{E}[D_i - p_i \mid \mathbf{X}_i] \mathbb{E}[Y_i(0) \mid \mathbf{X}_i] = 0.$$

- **Término B:** como $D_i \in \{0, 1\}$, se tiene $D_i^2 = D_i$, de modo que

$$(D_i - p_i)D_i = (1 - p_i)D_i.$$

Además, bajo **ignorabilidad**, $\tau_i \perp\!\!\!\perp D_i \mid \mathbf{X}_i$, luego

$$\begin{aligned}\mathbb{E}[(1 - p_i)D_i\tau_i \mid \mathbf{X}_i] &= (1 - p_i) \mathbb{E}[D_i \mid \mathbf{X}_i] \mathbb{E}[\tau_i \mid \mathbf{X}_i] \\ &= p_i(1 - p_i) \tau(\mathbf{X}_i).\end{aligned}$$

- Por lo tanto:

$$\mathbb{E}[\tilde{D}_i Y_i \mid \mathbf{X}_i] = \tau(\mathbf{X}_i) p_i(1 - p_i).$$

Demostración: $\text{plim } \hat{\tau}_{mco}$ (III)

- El denominador condicional en $\mathbf{X}_i$ es

$$\mathbb{E}[\tilde{D}_i^2 \mid \mathbf{X}_i] = \text{Var}(D_i \mid \mathbf{X}_i) = p_i(1 - p_i) \equiv \omega(\mathbf{X}_i).$$

- Esto implica que $\mathbb{E}[\tilde{D}_i Y_i \mid \mathbf{X}_i] = \tau(\mathbf{X}_i) \omega(\mathbf{X}_i)$.

- Aplicando la **ley de expectativas iteradas**:

$$\mathbb{E}[\tilde{D}_i Y_i] = \mathbb{E}[\tau(\mathbf{X}_i) \omega(\mathbf{X}_i)], \quad \mathbb{E}[\tilde{D}_i^2] = \mathbb{E}[\omega(\mathbf{X}_i)].$$

- Finalmente:

$$\text{plim } \hat{\tau}_{mco} = \frac{\mathbb{E}[\tau(\mathbf{X}_i) \omega(\mathbf{X}_i)]}{\mathbb{E}[\omega(\mathbf{X}_i)]}, \quad \omega(\mathbf{X}_i) = p_i(1 - p_i).$$

Demostración breve IPW (I)

- Consideremos la identidad para $Y_i(1)$ (el caso $Y_i(0)$ es análogo).
- Recordemos que $D_i \in \{0, 1\}$ y $Y_i = (1 - D_i)Y_i(0) + D_iY_i(1)$.
Sustituyendo en $\frac{D_i Y_i}{p_i}$:

$$\frac{D_i Y_i}{p_i} = \frac{D_i(1 - D_i)Y_i(0)}{p_i} + \frac{D_i^2 Y_i(1)}{p_i}.$$

Como $D_i(1 - D_i) = 0$ y $D_i^2 = D_i$: $\frac{D_i Y_i}{p_i} = \frac{D_i Y_i(1)}{p_i}$.

- Tomamos la esperanza condicional dado $\mathbf{X}_i$:

$$\begin{aligned}\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] &= \frac{1}{p_i} \mathbb{E}[D_i Y_i(1) \mid \mathbf{X}_i] \\ &= \frac{1}{p_i} \mathbb{E}[D_i \mathbb{E}[Y_i(1) \mid \mathbf{X}_i, D_i] \mid \mathbf{X}_i] \quad (\text{LEI}).\end{aligned}$$

Demostración breve IPW (II)

- Por **ignorabilidad**, $Y_i(1) \perp\!\!\!\perp D_i \mid \mathbf{X}_i$, de modo que

$$\mathbb{E}[Y_i(1) \mid \mathbf{X}_i, D_i] = \mathbb{E}[Y_i(1) \mid \mathbf{X}_i].$$

Así,

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] = \frac{1}{p_i} \mathbb{E}[Y_i(1) \mid \mathbf{X}_i] \mathbb{E}[D_i \mid \mathbf{X}_i].$$

Como $\mathbb{E}[D_i \mid \mathbf{X}_i] = p_i$, obtenemos:

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] = \mathbb{E}[Y_i(1) \mid \mathbf{X}_i].$$

- Finalmente, por la **ley de expectativas iteradas**:

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i}\right] = \mathbb{E}\left[\mathbb{E}[Y_i(1) \mid \mathbf{X}_i]\right] = \mathbb{E}[Y_i(1)].$$