

Econometría Avanzada

Diseño de Regresión Discontinua (RDD)

Manuel Fernández

7 de septiembre de 2026

Temas de la clase:

1. Motivación
2. Resultados potenciales
3. Continuidad local
4. Validación de los supuestos y ejercicios de robustez
5. Anexo
Regression Kink Design (RKD)

Motivación

Métodos experimentales y no experimentales

- RCTs evitan el problema de **sesgo de selección** a través de la **asignación aleatoria** al tratamiento.
- Los métodos de **matching o reponderación** buscan comparar grupos similares, ya sea **condicionando en un conjunto de características observables** o usando **pesos que rebalancean la muestra**.
- Otros **métodos no experimentales** buscan **aproximar el ideal experimental explotando fuentes de variación en la asignación plausiblemente exógenas**.
- Hoy nos enfocamos en el **diseño de regresión discontinua (RDD)**:
 1. **Discontinua nítida (RDN)** — tema de hoy.
 2. **Discontinua borrosa (RDB)** — en unas semanas.

Arbitrariedad en el método de asignación

- **Idea central:** en algunos contextos, el **método de asignación** al tratamiento sigue reglas que son **arbitrarias en el margen**.
 - **Programas sociales** con focalización por puntaje de SISBEN (e.g., Familias en Acción).
 - **Becas** con corte en una prueba estandarizada (e.g., Ser Pilo Paga según puntaje del Saber 11).
 - **Regulaciones laborales o tributarias** que cambian bruscamente según el tamaño de la firma (e.g., Régimen Simple de Tributación).
 - **Clasificación de municipios por población** (e.g., autonomía presupuestal).
- Estas reglas suelen surgir de decisiones administrativas.
- El **umbral específico** que determina la **asignación al tratamiento** tiene un grado de **arbitrariedad**.

Método de asignación

- Z_i : variable **continua** observada que determina la **asignación al tratamiento** (e.g., puntaje de SISBEN, resultado en Saber 11). Se conoce como *running variable* o *forcing variable*.
 - Puede ser multidimensional (e.g., RD geográfico).
- Z_0 : **umbral de elegibilidad** (conocido).
- $D_i \in \{0, 1\}$: variable indicadora de tratamiento.
- **Regla de asignación** (ejemplo):

$$D_i = \begin{cases} 1 & \text{si } Z_i \geq Z_0, \\ 0 & \text{si } Z_i < Z_0. \end{cases}$$


donde Z_0 suele fijarse de manera **exógena** (e.g., decisión administrativa).

- La **asignación no es aleatoria**: depende enteramente de Z_i .

Contexto apropiado para RD nítido

1. La **asignación al tratamiento** depende **únicamente** de la *running variable* Z_i y del umbral Z_0 . Es decir, D_i es una **función determinística** de Z_i .
 - **Cumplimiento perfecto**: todos los individuos con $Z_i \geq Z_0$ reciben el tratamiento, y ninguno con $Z_i < Z_0$ lo recibe.
2. Las unidades no pueden **manipular de forma precisa** la variable de asignación para garantizar su tratamiento.
3. El **punto de corte** Z_0 es conocido, fijo y correctamente especificado.


Discontinuidad en la probabilidad de recibir el tratamiento



- Hay una **discontinuidad** en la probabilidad de recibir el tratamiento en Z_0 .
- ¿Qué pasa con la variable de resultado, Y_i , alrededor de Z_0 ?

Ejemplo de salto en la variable de resultado

- Suponga que normalizamos todo para que $Z_0 = 0$.



- Y_i tiene una **discontinuidad** exactamente en Z_0 .
- Notar que Y_i puede ser una función de Z_i .

Resultados potenciales

Resultados potenciales

- Resultados potenciales:

$$Y_i = \begin{cases} Y_i(1) & \text{si } i \text{ recibe el tratamiento} \\ Y_i(0) & \text{si } i \text{ no recibe el tratamiento} \end{cases}$$

- Método de asignación:

$$D_i = \begin{cases} 1 & \text{si } Z_i \geq Z_0 \\ 0 & \text{si } Z_i < Z_0 \end{cases}.$$

- Implicaciones:

1. $Y_i(0), Y_i(1)$ **no son independientes** de la asignación al tratamiento D_i (Los tratados y no tratados pueden diferir sistemáticamente).
2. Bajo el **RDD nítido**: dado Z_i , los resultados potenciales son independientes de la asignación:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid Z_i.$$

Resultados potenciales y modelo de regresión

- La CEF en ausencia de tratamiento es:

$$\mathbb{E}[Y_i(0)|Z_i] = m(Z_i).$$

Por ahora, somos agnósticos sobre la forma funcional $m(\cdot)$.

- Estamos interesados en el efecto **CATE**:

$$\tau(Z_i) \equiv \mathbb{E}[Y_i(1) - Y_i(0)|Z_i].$$

- El modelo que resulta es:

$$Y_i = m(Z_i) + \tau(Z_i)D_i + \epsilon_i,$$

donde $\mathbb{E}[\epsilon_i | Z_i] = 0$.

El problema de identificación

- Consideremos comparar resultados promedio a una distancia $\eta > 0$ del umbral:

1. $\mathbb{E}[Y_i|Z_i = Z_0 - \eta] = m(Z_0 - \eta).$

2. $\mathbb{E}[Y_i|Z_i = Z_0 + \eta] = m(Z_0 + \eta) + \tau(Z_0 + \eta).$

- Si definimos $\tau_{dif}(\eta) \equiv \mathbb{E}[Y_i|Z_i = Z_0 + \eta] - \mathbb{E}[Y_i|Z_i = Z_0 - \eta]$,

$$\tau_{dif}(\eta) = \tau(Z_0 + \eta) + \underbrace{m(Z_0 + \eta) - m(Z_0 - \eta)}_{\text{Sesgo de seleccin}}.$$

Continuidad local

Supuesto de identificación (RDD nítido)

$$\lim_{z \rightarrow Z_0^-} \mathbb{E}[Y_i(d) \mid Z_i = z] = \lim_{z \rightarrow Z_0^+} \mathbb{E}[Y_i(d) \mid Z_i = z] \text{ para } d \in \{0, 1\}.$$

De forma equivalente, $m(\cdot)$ y $\tau(\cdot)$ son continuas en Z_0 .

- **Intuición:** la relación entre Z y los resultados potenciales es **suave** en la vecindad del corte; cualquier salto de Y en Z_0 se debe al tratamiento.

- Diferencia de medias a distancia $\eta > 0$ del corte:

$$\tau_{dif}(\eta) = \tau(Z_0 + \eta) + \underbrace{m(Z_0 + \eta) - m(Z_0 - \eta)}_{\text{Sesgo de seleccin}}.$$

- En el **límite**, cuando $\eta \rightarrow 0$:


$$\lim_{\eta \rightarrow 0} \tau_{dif}(\eta) = \tau(Z_0).$$

Bajo **continuidad local**, comparar promedios justo a la izquierda y derecha de Z_0 identifica el **CATE en el umbral** de la *running variable*.

- Existen dos estrategias para identificar $\tau(Z_0)$:
 1. **Modelar la función continua** $m(Z_i)$ de forma adecuada. La idea es **separar** la **discontinuidad en el umbral Z_0** de la tendencia suave de $m(Z_i)$.
 2. **Restringir la comparación** a unidades ubicadas **muy cerca** del corte Z_0 , donde la continuidad local es más creíble.
- En la práctica, los métodos de RDD combinan **ambas ideas**: aproximar la función subyacente $m(Z_i)$ y concentrar el análisis en una **ventana estrecha** alrededor del umbral.


Ejemplo de RDN con $m(Z)$ bien especificada

$$Y_i = m(Z_i) + \tau D_i + \epsilon_i$$



- **Intuición:** MCO ajusta la tendencia continua $m(Z)$ y aísla la discontinuidad atribuible al tratamiento.

Ejemplo de RDN con $m(Z)$ mal especificada



- **Problema:** el ajuste incorrecto de $m(Z)$ puede atribuir parte de la tendencia continua al salto, generando **sesgo en la estimación**.

Polinomios globales

- Una opción es aproximar $m(Z_i)$ con un **polinomio de grado P** :

$$m(Z_i) = \beta_0 + \beta_1 Z_i + \beta_2 Z_i^2 + \dots + \beta_P Z_i^P.$$

La regresión que resulta es

$$Y_i = \beta_0 + \beta_1 Z_i + \beta_2 Z_i^2 + \dots + \beta_P Z_i^P + \tau(Z_0) D_i + \epsilon_i.$$

- **Ventaja:** entre más alto el grado P , mayor flexibilidad para capturar la forma de $m(Z)$.
- **Problemas:**
 - Estimadores menos precisos (alta varianza).
 - Resultados muy sensibles a la elección de P .
 - Riesgo de sobreajuste y oscilaciones espurias en los extremos.
- Recomendación práctica: usar polinomios de **grado bajo** ($P \leq 2$) (Gelman and Imbens, 2014).

Restricción a la vecindad del umbral

- La idea es comparar unidades **muy cercanas** al **umbral** Z_0 . En el **límite**, cuando $\eta \rightarrow 0$:

$$\lim_{\eta \rightarrow 0} \tau_{\text{dif}}(\eta) = \tau(Z_0).$$




- En la práctica, aproximamos este límite restringiendo la muestra a una **ventana simétrica** alrededor de Z_0 :

$$Z_i \in [Z_0 - h, Z_0 + h],$$

donde h es el **ancho de banda**.

- Dentro de esa ventana, el **efecto causal local** se puede estimar como una simple **diferencia de medias** entre las observaciones a cada lado del corte.

Diferencia de medias en la vecindad de Z_0



Aleatorización local

- **Intuición:** si usamos solo las observaciones en un rango muy estrecho alrededor de Z_0 , el **sesgo de selección** desaparece en el límite: no hay selección **localmente**.
- **Aleatorización local:** los individuos justo a la izquierda y a la derecha del umbral son comparables **como si hubieran sido asignados al azar** a tratamiento y control.
- Problema práctico: al reducir el ancho de banda h , disminuye el sesgo pero también el número de observaciones $\Rightarrow$ **estimadores menos precisos**.
- **Trade-off sesgo-varianza:** elegir h implica balancear entre reducir el sesgo (ventanas pequeñas) y mantener precisión (ventanas grandes).

Regresión local: intuición

- En vez de ajustar un polinomio **global**, nos concentramos en una **ventana** alrededor del umbral Z_0 .
- Dentro de esa ventana:
 - Se ajusta una función $m(Z)$ sencilla (lineal o cuadrática).
 - Se asignan **más peso** a las observaciones cercanas al corte, usando un kernel $K(\cdot)$.
- La idea es estimar $m(Z)$ **separadamente a cada lado del umbral** y luego comparar las predicciones en Z_0 . Esto nos da un estimador local de $\tau(Z_0)$.

Regresión local: formalización

1. Elegir el orden del polinomio (P) y la función de pesos $K(\cdot)$.
2. Seleccionar un ancho de banda h (óptimo en MSE).
3. Estimar por **mínimos cuadrados ponderados** en cada lado de Z_0 :

$$\hat{\beta}_{-} = \arg \min_{\beta_{0,-}, \beta_{1,-}} \sum_{i=1}^n \mathbf{1}[Z_i < Z_0] (Y_i - \beta_{0,-} - \beta_{1,-}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right),$$

$$\hat{\beta}_{+} = \arg \min_{\beta_{0,+}, \beta_{1,+}} \sum_{i=1}^n \mathbf{1}[Z_i \geq Z_0] (Y_i - \beta_{0,+} - \beta_{1,+}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right).$$

$$\tau(Z_0) \mid h = \hat{\beta}_{0,+} - \hat{\beta}_{0,-}.$$

- La inferencia requiere correcciones (e.g. Calonico et al. 2014).

Ejemplo: ? (elecciones cerradas)

- **Pregunta:** ¿Cuál es el efecto causal de que un partido gane una elección en t sobre su probabilidad de ganar la elección siguiente (en $t + 1$)?
- **Contexto:**
 - Elecciones a la Cámara de Representantes de EE. UU., a nivel de distrito electoral.
 - Muestra: 6,558 elecciones entre 1946–1998
 - Sistema fuertemente bipartidista: Demócratas vs. Republicanos.
- **Variable de asignación:** Diferencia en el porcentaje de votos entre Demócratas y su competidor más cercano en el distrito i en el año t :

$$Z_{i,t} = V_{i,t}^d - V_{i,t}^r.$$

- Umbral: $Z_0 = 0$.

- Tratamiento: ganar la elección en t :

$$D_{i,t} = \mathbf{1}\{Z_{i,t} > 0\}.$$


- Variable resultado (entre otras): probabilidad de ganar la elección en $t + 1$:

$$Y_{i,t+1} = \mathbf{1}\{V_{i,t+1}^d - V_{i,t+1}^r > 0\},$$

donde $\mathbf{1}\{\cdot\}$ es la función indicadora.

- Estimación: regresión local alrededor del umbral ($Z_0 = 0$).

La ventaja de la incumbencia (?)




Nota: Ancho de banda 0.005 (200 bins).

- Si los Demócratas ganan marginalmente una elección, la probabilidad de ganar en la siguiente incrementa en ≈ 0.4 .


Validación de los supuestos y ejercicios de robustez

Continuidad local en variables exógenas (?)



- Las variables exógenas, como el margen de votación en $t - 1$, no deberían mostrar discontinuidades en el umbral $Z_{i,t} = 0$.


Manipulación de Z_i (?)




- McCrary (2008) propone un test estadístico para detectar manipulación: mirar si la densidad del *running variable* es continua en el umbral.

Robustez respecto al ancho de banda (?)


(a) Ancho de banda 0.001 (100 bins)



(b) Ancho de banda 0.02 (50 bins)



(c) Ancho de banda 0.005 (200 bins)



- RD con reglas de asignación multidimensionales (lectura Londoño-Vélez et al. (2023) y Dell (2010)).
- RD geográfico (lectura Dell (2010)).
- Regression Kink Design (RKD) en el anexo.


Anexo

Introducción a RKD

- RDD explota el **salto en la probabilidad** de recibir un tratamiento en el umbral de elegibilidad.
- RKD explota un **cambio en la pendiente** de la relación entre la variable de asignación (Z) y la variable de tratamiento (X) en un punto de quiebre o “*kink*” (Z_0).
 - Cambio en la tasa marginal del impuesto sobre la renta en ciertos niveles de ingreso.
 - Tarifas de emisión de CO2 que aumentan después de superar un límite específico.
- La idea es analizar cómo la pendiente de la relación entre la variable de resultado (Y_i) y la variable de asignación (Z) cambia en Z_0 .


Cambio en la pendiente de la variable de tratamiento

- Suponga que hay un incremento en la tasa marginal de tributación a partir de un ingreso normalizado de $Z = 0$.



- **Pregunta:** ¿El incremento en los impuestos desincentiva la oferta laboral?

Cambio en la pendiente de la variable de resultado



- A la izquierda del punto de quiebre Z_0 , la relación entre ingreso y horas trabajadas tiene una pendiente negativa.
- Esta pendiente negativa se intensifica justo en Z_0 .

Identificación

- Estamos interesados en el efecto causal de un aumento en los impuestos sobre las horas trabajadas en el punto de quiebre:

$$\tau(Z_0) \equiv \mathbb{E} \left[\frac{dY}{dX} \mid Z = Z_0 \right]$$

- Según Nielsen et al. (2010) y Card et al. (2012), bajo condiciones de regularidad:

$$\tau(Z_0) = \frac{\lim_{\eta \rightarrow 0} \frac{d \mathbb{E}[Y|Z=Z_0+\eta]}{dZ} - \lim_{\eta \rightarrow 0} \frac{d \mathbb{E}[Y|Z=Z_0-\eta]}{dZ}}{\lim_{\eta \rightarrow 0} \frac{d \mathbb{E}[X|Z=Z_0+\eta]}{dZ} - \lim_{\eta \rightarrow 0} \frac{d \mathbb{E}[X|Z=Z_0-\eta]}{dZ}}$$

- Requerimos que cerca del umbral todo cambie “suavemente” excepto la derivada de la relación entre la variable de asignación y la variable de tratamiento.
- RKD estima el cambio en la pendiente de la respuesta, ajustado por el cambio en la pendiente de la variable de tratamiento.

Estimación (polinomio de primer orden)

- Numerador:

$$\hat{\beta}_{-} = \arg \min_{\beta_{0,-}, \beta_{1,-}} \sum_{i=1}^n \mathbf{1}[Z_i < Z_0] (Y_i - \beta_{0,-} - \beta_{1,-}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right),$$

$$\hat{\beta}_{+} = \arg \min_{\beta_{0,+}, \beta_{1,+}} \sum_{i=1}^n \mathbf{1}[Z_i \geq Z_0] (Y_i - \beta_{0,+} - \beta_{1,+}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right).$$

- Denominador:

$$\hat{\gamma}_{-} = \arg \min_{\gamma_{0,-}, \gamma_{1,-}} \sum_{i=1}^n \mathbf{1}[Z_i < Z_0] (X_i - \gamma_{0,-} - \gamma_{1,-}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right),$$

$$\hat{\gamma}_{+} = \arg \min_{\gamma_{0,+}, \gamma_{1,+}} \sum_{i=1}^n \mathbf{1}[Z_i \geq Z_0] (X_i - \gamma_{0,+} - \gamma_{1,+}(Z_i - Z_0))^2 K\left(\frac{Z_i - Z_0}{h}\right).$$

- Estimador:

$$\hat{\tau}(Z_0) = \frac{\hat{\beta}_{1,+} - \hat{\beta}_{1,-}}{\hat{\gamma}_{1,+} - \hat{\gamma}_{1,-}}.$$