

# Econometría Avanzada

## Diferencias en Diferencias (DiD) II

---

Manuel Fernández

9 de julio de 2026

## Temas de la clase:

1. Efectos fijos
2. Modelo de diferencias en diferencias (Cont.)
3. Supuesto de tendencias paralelas
4. Cambios en la composición y formas funcionales
5. Modelo de diferencias en diferencias en diferencias (DDD)
6. Estudio de eventos

## **Efectos fijos**

---

# ¿Qué es un efecto fijo?

- Un **efecto fijo** es un término (intercepto) específico de cada unidad (o de cada período) que se mantiene **constante en el tiempo para esa unidad**, usado para **capturar heterogeneidad no observada invariante en el tiempo**.
- En modelos con datos panel, un modelo con **efectos fijos en dos direcciones** (*TWFE*) típicamente se escribe como:

$$Y_{it} = \phi_t + \eta_i + \mathbf{X}_{it}'\beta + e_{it}$$

donde  $(\phi_t, \eta_i)$  son parámetros que podemos estimar.

- **Interpretación:**
  - $\eta_i$ : controla por diferencias **invariables en el tiempo** entre unidades.
  - $\phi_t$ : controla por diferencias **comunes en el tiempo** a todas las unidades.

# Ejemplos

## 1. Flujos migratorios y nivel de empleo de la población nativa

(Tabellini, 2020):

- $Y_{it}$ : tasa de ocupación de la población nativa en la ciudad  $i$  y año  $t$ .
- $X_{it}$ : porcentaje de inmigrantes relativo a la población total en la ciudad  $i$  y año  $t$ .
- $\eta_i$ : ...
- $\phi_t$ : ...

## 2. Precio de materias primas y conflicto armado en Colombia (Dube and Vargas, 2013):

- $Y_{it}$ : número de ataques de grupos guerrilleros o paramilitares en el municipio  $i$  y año  $t$ .
- $X_{it}$ : precio internacional del petróleo/café en año  $t$  interactuado con producción de petróleo/café en el municipio  $i$  y año  $t$ .
- $\eta_i$ : ...
- $\phi_t$ : ...

- **Pregunta de investigación:** cuantificar los retornos a la educación.
- **Problema:**



Endogeneidad por variable omitida (e.g., habilidad, características familiares).

- **Estrategia de identificación:** comparar gemelos idénticos (monocigóticos) con diferentes niveles de educación  $\implies$  controlar por características genéticas y del entorno familiar.

- Modelo para cada gemelo:

$$Y_{i1} = \eta_i + \mathbf{X}'_{i1}\beta + e_{i1}$$

$$Y_{i2} = \eta_i + \mathbf{X}'_{i2}\beta + e_{i2}$$

1.  $Y_{ij}$ : *log* salario del gemelo  $j$  en el hogar  $i$ .
2.  $\mathbf{X}_{ij}$ : covariables con **variación entre gemelos** (p.ej., **educación**, experiencia, estado civil).
3.  $\eta_i$ : constante entre gemelos (p.ej., dotación genética, ambiente del hogar).

$$Y_{i1} - Y_{i2} = (\mathbf{X}_{i1} - \mathbf{X}_{i2})'\beta + e_{i1} - e_{i2}$$

$$Y_i^* = \mathbf{X}_i'^* \beta + e_i^*.$$

TABLE 3—ORDINARY LEAST-SQUARES (OLS), GENERALIZED LEAST-SQUARES (GLS), INSTRUMENTAL-VARIABLES (IV), AND FIXED-EFFECTS ESTIMATES OF LOG WAGE EQUATIONS FOR IDENTICAL TWINS<sup>a</sup>

| Variable               | OLS<br>(i)        | GLS<br>(ii)       | GLS<br>(iii)      | IV <sup>a</sup><br>(iv) | First<br>difference<br>(v) | First<br>difference by IV<br>(vi) |
|------------------------|-------------------|-------------------|-------------------|-------------------------|----------------------------|-----------------------------------|
| Own education          | 0.084<br>(0.014)  | 0.087<br>(0.015)  | 0.088<br>(0.015)  | 0.116<br>(0.030)        | 0.092<br>(0.024)           | 0.167<br>(0.043)                  |
| Sibling's<br>education | —                 | —                 | -0.007<br>(0.015) | -0.037<br>(0.029)       | —                          | —                                 |
| Age                    | 0.088<br>(0.019)  | 0.090<br>(0.023)  | 0.090<br>(0.023)  | 0.088<br>(0.019)        | —                          | —                                 |
| Age squared<br>(÷ 100) | -0.087<br>(0.023) | -0.089<br>(0.028) | -0.090<br>(0.029) | -0.087<br>(0.024)       | —                          | —                                 |
| Male                   | 0.204<br>(0.063)  | 0.204<br>(0.077)  | 0.206<br>(0.077)  | 0.206<br>(0.064)        | —                          | —                                 |
| White                  | -0.410<br>(0.127) | -0.417<br>(0.143) | -0.424<br>(0.144) | -0.428<br>(0.128)       | —                          | —                                 |
| Sample size:           | 298               | 298               | 298               | 298                     | 149                        | 149                               |
| R <sup>2</sup> :       | 0.260             | 0.219             | 0.219             | —                       | 0.092                      | —                                 |

Notes: Each equation also includes an intercept term. Numbers in parentheses are estimated standard errors.

<sup>a</sup>Own education and sibling's education are instrumented for using each sibling's report of the other sibling's education as instruments.

## **Modelo de diferencias en diferencias (Cont.)**

## Modelo de DiD (Cont.)

- El modelo de **diferencias en diferencias** (DiD) se puede plantear, **bajo ciertas condiciones**, como un modelo de *TWFE*.

- **Notación:**

- $t \in \{0, 1, \dots, T\}$ : índice de periodos.
- $i \in \{1, \dots, N\}$ : índice de unidades.
- $t_0 \in \{1, \dots, T\}$ : periodo en el que inicia el tratamiento.

Asumimos (por ahora):

- i) **Estado absorbente**: una vez tratada, la unidad permanece tratada.
- ii) **Tratamiento simultáneo**: todas las unidades tratadas comienzan en  $t_0$ .
- $D_i \in \{0, 1\}$ : indicador de pertenencia al grupo tratado.
- $D_{it} = D_i \cdot \mathbf{1}\{t \geq t_0\}$ : indicador *post* para unidades tratadas.

## Diseño de investigación (causal)

Declaración estadística y/o económica de cómo se estimará una relación entre dos (o más) variables que es de **naturaleza causal**.

- Los diseños pueden clasificarse en dos enfoques:
  - **Basado en la asignación**: el **estimando** se identifica a partir de supuestos sobre el mecanismo de asignación del tratamiento (e.g., experimentos controlados).
  - **Basado en modelos**: el **estimando** se identifica modelando los resultados potenciales.
- Para pensar en las extensiones de DiD, vamos a tomar un enfoque **basado en modelos** a partir de los supuestos de identificación.

# Tendencias paralelas

- **Tendencias paralelas (S1)**: En **ausencia de tratamiento**, los grupos tratado y control siguen la **misma evolución temporal** (pueden diferir en niveles, pero no en su tendencia).

$$\mathbb{E}[Y_{it}(0) \mid D_i] = \phi_t + \eta_i \quad \forall t, D_i \in \{0, 1\}.$$

- $\phi_t$  es la **tendencia común de tiempo**.
- $\eta_i$  es un efecto fijo de unidad (o de grupo). Captura las **diferencias sistemáticas** que son constantes en el tiempo.

$\Rightarrow \mathbb{E}[Y_{it}(0)]$  se descompone aditivamente en un **efecto fijo de unidad** y un **efecto fijo de tiempo**.

# No anticipación y SUTVA

- **No anticipación (S2):**

Para todo  $t < t_0$ , no hay efecto del tratamiento:

$$Y_{it}(1) = Y_{it}(0) = Y_{it} \implies \mathbb{E}[Y_{it} | D_i] = \mathbb{E}[Y_{it}(0) | D_i].$$

En palabras: antes de la implementación ( $t_0$ ), los resultados potenciales con y sin tratamiento coinciden.

- **SUTVA (S3):**

$$Y_{it}(D_i, \mathbf{D}_{-i}) = Y_{it}(D_i)$$

donde  $\mathbf{D}_{-i}$  denota el vector de asignaciones de todas las demás unidades.

**En palabras:** el resultado de la unidad  $i$  depende únicamente de su propia asignación (sin *spillovers* o interferencia).

# Modelo con efectos constantes y homogéneos

- Considere (por ahora) el caso más sencillo con **efectos constantes y homogéneos**:

$$\mathbb{E}[Y_{it}(1) - Y_{it}(0) \mid D_i = 1] = \tau, \quad \forall t \geq t_0.$$

- **Combinando S1–S3 y homogeneidad:**

$$\begin{aligned}\mathbb{E}[Y_{it} \mid D_{it} = 1] &= \mathbb{E}[Y_{it}(0) \mid D_{it} = 1] + \tau \\ &= \phi_t + \eta_i + \tau.\end{aligned}$$

Recordar que  $D_{it} = D_i \cdot \mathbf{1}\{t \geq t_0\}$ .

- **Para**  $D_{it} = 0$ ,

$$\mathbb{E}[Y_{it} \mid D_{it} = 0] = \mathbb{E}[Y_{it}(0) \mid D_{it} = 0] = \phi_t + \eta_i.$$

- Representación *TWFE* de la CEF bajo S1-S3:

$$\mathbb{E}[Y_{it} \mid D_{it}] = \phi_t + \eta_i + \tau D_{it}.$$

- Por las propiedades de la CEF:

$$Y_{it} = \phi_t + \eta_i + \tau D_{it} + e_{it}, \quad \text{donde } \mathbb{E}[e_{it} \mid D_{it}] = 0.$$

Se desprende que  $\text{plim } \hat{\tau}_{TWFE} = \tau$ .

- Bajo S1–S3 y efectos homogéneos ( $\tau$ ), para dos unidades  $i$  (tratada) y  $j$  (control), y para  $k, h \in \mathbb{N}^+$ :

1.  $\mathbb{E}[Y_{i, t_0+k} \mid D_i = 1] = \phi_{t_0+k} + \eta_i + \tau$

2.  $\mathbb{E}[Y_{i, t_0-h} \mid D_i = 1] = \phi_{t_0-h} + \eta_i$

3.  $\mathbb{E}[Y_{j, t_0+k} \mid D_j = 0] = \phi_{t_0+k} + \eta_j$

4.  $\mathbb{E}[Y_{j, t_0-h} \mid D_j = 0] = \phi_{t_0-h} + \eta_j$

- Diferencias en diferencias:

$$\tau = \left( (1) - (2) \right) - \left( (3) - (4) \right) = \tau_{\text{DiD}}$$

# Efectos dinámicos (1)

1. **Efectos dinámicos (post)**. Defina el tiempo relativo  $j \equiv t - t_0$ . Para  $j \geq 0$  (periodos post):

$$\tau_j = \mathbb{E} [Y_{it}(1) - Y_{it}(0) | D_i = 1, t = j + t_0].$$

**Intuición:**  $\tau_j$  es el efecto promedio  $j$  periodos después de la implementación.

- Podemos extendernos a un **modelo dinámico** de la forma:

$$Y_{it} = \phi_t + \eta_i + \sum_{j=0}^{T-t_0} \tau_j D_i \mathbf{1}\{j = t - t_0\} + e_{it}.$$

Hay un efecto estimado para cada periodo relativo  $j \geq 0$ .

## Efectos dinámicos (2)

2. Efectos dinámicos (pre). Para  $j < 0$  (periodos pre):

$$\tau_j = \mathbb{E}[Y_{it}(1) - Y_{it}(0) \mid D_i, t = j + t_0] = 0.$$

¿Por qué? ¿Qué implica que  $\tau_j \neq 0$  para  $j < 0$ ?

- Considere el **modelo dinámico** ampliado:

$$Y_{it} = \phi_t + \eta_i + \sum_{j \neq -1} \tau_j D_i \mathbf{1}\{j = t - t_0\} + e_{it}.$$

Se debería cumplir que  $\tau_j = 0$  para  $j < -1$ .

- Tenemos que elegir un periodo de referencia previo a la implementación del tratamiento (e.g.,  $j = -1$ ) ¿Por qué?  
¿Importa qué periodo?
- Los efectos se interpretan relativo a la diferencia (tratamiento vs. control) en ese periodo.

# Modelo *TWFE* con efectos dinámicos y heterogéneos

3. Con **efectos heterogéneos** ( $\tau_{ij}$ ), los parámetros  $\tau_j$  del **modelo dinámico** (o el  $\tau$  del **modelo estático**) se pueden interpretar como un promedio ponderado en cada tiempo relativo:

$$\tau_j = \mathbb{E}[\tau_{ij} \mid D_i, t = j + t_0].$$

donde los pesos están dados por la forma del estimador MCO (recordar diapositivas de *matching*).

- **Importante:** esto no aplica para **estudio de eventos** donde  $t_0$  puede variar entre cohortes.

## **Supuesto de tendencias paralelas**

---

# Supuesto de tendencias paralelas


- El supuesto de **tendencias paralelas** se puede validar **parcialmente** si tenemos datos para varios **periodos pretratamiento**.
- **Intuición**: la diferencia entre las unidades tratadas y de control en cualquier período previo al tratamiento es constante. Si el modelo es:

$$Y_{it} = \phi_t + \eta_i + \sum_{j \neq -1} \tau_j D_i \mathbf{1}[j = t - t_0] + e_{it},$$

se debería cumplir que  $\tau_j = 0$  para  $j < -1$ .

# Representación gráfica (1)


- Suponga que usted hace una figura con el promedio de  $Y$  para ambos grupos  $D \in \{0, 1\}$ :



donde  $j = t - t_0$ . ¿Se cumple el supuesto de tendencias paralelas pretratamiento?


## Representación gráfica (2)

- Suponga ahora que usted observa:




donde  $j = t - t_0$ . ¿Se cumple el supuesto de tendencias paralelas pretratamiento?



## Ejemplo 1: Movilidad durante la pandemia (tendencias)



## Ejemplo 1: Movilidad durante la pandemia (modelo dinámico)



## Ejemplo 2: coca y PNIS (modelo dinámico)



## **Cambios en la composición y formas funcionales**

# Cambios en la composición

- El tratamiento puede **cambiar la composición** de los grupos.
- Suponga que un departamento diseña una política de transferencias condicionales para ayudar a la población migrante.
  1. Induce a ciertas personas a trasladarse a este departamento.
  2. Las personas que se mueven son (potencialmente) diferentes a los que se quedan.
- Incluso si la política no tiene ningún efecto real, la composición de la muestra en cada grupo puede cambiar, lo que puede generar efectos espurios.

# Forma funcional

- El cumplimiento del supuesto de **tendencias paralelas** puede depender de la forma funcional con la que modelamos la variable de resultado.
- Considere los siguientes modelos:

$$Y_{it} = \phi_t + \eta_i + \tau D_{it} + e_{it},$$

$$\ln Y_{it} = \phi_t + \eta_i + \tau D_{it} + e_{it}.$$

- Suponga que el tratamiento corresponde a un programa de empleo, con los siguientes cambios observados:
  - El empleo sube de 20 % a 30 % para el grupo tratado.
  - El empleo sube de 5 % a 10 % para el grupo de control.
  - **Efecto DiD (niveles)**: aumento de 5 puntos porcentuales.
  - **Efecto DiD (logaritmos)**:

$$[\ln(30) - \ln(20)] - [\ln(10) - \ln(5)] = \ln(1.5) - \ln(2) < 0.$$

## **Modelo de diferencias en diferencias en diferencias (DDD)**

---

# Modelo de diferencias en diferencias en diferencias (DDD)

- Cuando no se cumple **tendencias paralelas**, una tercera diferencia puede ayudar con la identificación.
- Ejemplo: **Muralidharan and Prakash (2017)**:
  - En el estado de Bihar, India, se diseñó una intervención para reducir la brecha entre hombres y mujeres en la cobertura de educación secundaria.
  - Las **mujeres** que permanecían en la escuela **recibían una bicicleta** que les facilitaba trasladarse al colegio, reduciendo el costo de movilidad.
  - **Los hombres** no recibían nada.

- Una posibilidad es estimar un modelo de DiD comparando la tasa de cobertura de las mujeres antes y después del tratamiento, usando a los hombres en las mismas cohortes como grupo de control.

$$y_{gt} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 \text{Mujer}_g + \beta_3 (\text{Post}_t \times \text{Mujer}_g) + e_{gt},$$

donde:

- $g$  indexa el sexo (hombre/mujer),
  - $t$  indexa el período (pre/post),
  - $y_{gt}$  es la tasa de cobertura en el estado de Bihar para el grupo  $g$  en el período  $t$ .
- 
- El coeficiente  $\beta_3$  estima el efecto a través de una comparación por DiD.

## ¿Una nueva diferencia?

- **Problema:** hombres y mujeres pueden presentar **tendencias distintas** en las tasas de cobertura; es decir, la brecha de género podría no ser constante en el tiempo.
- Sin embargo, es razonable suponer que dicha brecha sigue una trayectoria similar en estados no tratados: esto implica **tendencias paralelas** en la **brecha de género** entre estados en **ausencia del tratamiento**.

$$DDD = DiD_{Bihar} - DiD_{Jharkhand}$$

- $DiD_{Bihar}$ : Efecto causal + cambio en la brecha de género.
- $DiD_{Jharkhand}$ : Cambio en la brecha de género.

- Modelo extendido con una **tercera diferencia** (estado, período, género):

$$\begin{aligned} y_{sgt} = & \beta_0 + \beta_1 \text{Bihar}_s + \beta_2 \text{Post}_t + \beta_3 \text{Mujer}_g \\ & + \beta_4 (\text{Bihar}_s \times \text{Mujer}_g) + \beta_5 (\text{Bihar}_s \times \text{Post}_t) \\ & + \beta_6 (\text{Post}_t \times \text{Mujer}_g) + \tau (\text{Bihar}_s \times \text{Post}_t \times \text{Mujer}_g) + \varepsilon_{sgt} \end{aligned}$$

- El coeficiente  $\tau$  estima el efecto diferencial del tratamiento sobre las mujeres en Bihar, controlando por diferencias comunes a género, tiempo y estado.
- Hay una versión equivalente con efectos fijos. Intente derivarla.

# Ejemplo: Muralidharan and Prakash (2017)

TABLE 2—TRIPLE DIFFERENCE (DDD) ESTIMATE OF THE IMPACT OF BEING EXPOSED TO THE CYCLE PROGRAM ON GIRL'S SECONDARY SCHOOL ENROLLMENT

| Dependent variable: Enrolled in or completed grade 9 |                                |                                |                                |                                |
|------------------------------------------------------|--------------------------------|--------------------------------|--------------------------------|--------------------------------|
| Treatment group = age 14 and 15                      |                                |                                |                                |                                |
| Control group = age 16 and 17                        | (1)                            | (2)                            | (3)                            | (4)                            |
| <b>Treat × female × Bihar</b>                        | <b>0.103</b><br><b>(0.030)</b> | <b>0.091</b><br><b>(0.029)</b> | <b>0.052</b><br><b>(0.025)</b> | <b>0.052</b><br><b>(0.025)</b> |
| Treat × female                                       | 0.020<br>(0.026)               | 0.024<br>(0.026)               | 0.038<br>(0.021)               | 0.039<br>(0.021)               |
| Treat × Bihar                                        | −0.044<br>(0.018)              | −0.042<br>(0.018)              | −0.029<br>(0.016)              | −0.028<br>(0.016)              |
| Female × Bihar                                       | −0.094<br>(0.023)              | −0.091<br>(0.023)              | −0.067<br>(0.020)              | −0.066<br>(0.020)              |
| Treat                                                | −0.148<br>(0.014)              | −0.143<br>(0.014)              | −0.138<br>(0.013)              | −0.138<br>(0.013)              |
| Female                                               | −0.092<br>(0.020)              | −0.088<br>(0.020)              | −0.100<br>(0.017)              | −0.101<br>(0.017)              |
| Bihar                                                | 0.011<br>(0.016)               | −0.044<br>(0.016)              | −0.032<br>(0.015)              | −0.044<br>(0.015)              |
| Constant                                             | 0.464<br>(0.013)               | 0.771<br>(0.024)               | 0.593<br>(0.027)               | 0.562<br>(0.040)               |
| Demographic controls                                 | No                             | Yes                            | Yes                            | Yes                            |
| HH socioeconomic controls                            | No                             | No                             | Yes                            | Yes                            |
| Village level controls                               | No                             | No                             | No                             | Yes                            |
| Observations                                         | 30,295                         | 30,295                         | 30,147                         | 30,112                         |
| R <sup>2</sup>                                       | 0.035                          | 0.088                          | 0.207                          | 0.208                          |

*Notes:* The demographic controls include dummies for scheduled caste, scheduled tribes, other backward caste, Hindu, and Muslim. HH socioeconomic controls include HH head years of schooling, dummies for HH head male, marginal farmer, below poverty line, TV/radio ownership, and access to electricity. Village controls include distance to bus station, nearest town, railway station, district headquarters, dummy for middle school, bank, post office, and log of village current population. These are the full set of variables for which descriptive statistics are presented in Table A.1 in the online Appendix. Standard errors, clustered by district ID, are in parentheses.

- Resumen del trabajo en este [enlace](#).

## **Estudio de eventos**

---

# Estudio de eventos

- Un estudio de eventos (diseño escalonado) es una generalización de diferencias en diferencias cuando las unidades pueden recibir el tratamiento en diferentes momentos del tiempo.
- **Notación (adicional):**
  - $G_i = \min\{t : D_{it} = 1\}$ : el primer periodo en el que la unidad  $i$  recibe tratamiento.
    - i) **Estado absorbente**: una vez tratada, la unidad permanece tratada.
    - ii) Si la unidad nunca es tratada, usamos  $G_i = \infty$ .
    - iii) Todas las unidades que comparten un mismo  $G_i$  hacen parte de la misma **cohorte**.
  - $Y_{it}(g)$ : resultado potencial de  $i$  en  $t$  si hubiese sido tratada por primera vez en  $G_i = g$ .
  - $Y_{it}(\infty)$ : resultado potencial de  $i$  en  $t$  si nunca hubiese sido tratada ( $G_i = \infty$ ).

## Estimandos más usados

- **ATT por grupo-periodo (cohorte  $G_i = g$ , tiempo  $t$ ):**

$$ATT(g, t) = \mathbb{E} [Y_{it}(g) - Y_{it}(\infty) \mid G_i = g].$$

- **ATT por *tiempo relativo*  $j = t - G_i \geq 0$ :**

$$ATT_j^\omega = \sum_g \omega_g ATT(g, g+j), \quad \text{con } \omega_g \geq 0 \text{ y } \sum_g \omega_g = 1.$$

- **ATT global (para  $j = t - G_i \geq 0$ ):**

$$ATT^\omega = \sum_j \sum_g \omega_{g,j} ATT(g, g+j), \quad \text{con } \omega_{g,j} \geq 0 \text{ y } \sum_j \sum_g \omega_{g,j} = 1.$$

# Cambios en los supuestos

- **Tendencias paralelas generalizadas (S1b)**: Para todo  $t \neq t'$  y  $g \neq g'$ ,

$$\mathbb{E}[Y_{it}(\infty) - Y_{it'}(\infty) \mid G_i = g] = \mathbb{E}[Y_{it}(\infty) - Y_{it'}(\infty) \mid G_i = g'].$$

En palabras, en **ausencia del tratamiento**, la variación promedio entre  $t$  y  $t'$  sería la misma para cualquier par de cohortes  $g$  y  $g'$  (incluyendo el grupo nunca tratado).

- **No anticipación (S2b)**:

**Para todo**  $t < g$ , no hay efecto del tratamiento:

$$Y_{it}(g) = Y_{it}(\infty).$$

- El supuesto de SUTVA **(S3)** se mantiene igual.

## ¿El modelo TWFE estático sigue siendo válido?

- Considere el **modelo estático** de TWFE:

$$Y_{it} = \phi_t + \eta_i + \tau^{twfe} D_{it} + e_{it}.$$

En **diseños escalonados**, el **efecto estimado por MCO** ( $\hat{\tau}_{mco}^{twfe}$ ) **no siempre tiene una interpretación causal “intuitiva”**, incluso si se cumplen los supuestos descritos.

- **Excepción:** no hay heterogeneidad en los efectos del tratamiento
  1. A lo largo del tiempo (**efectos constantes**),
  2. Entre unidades (**efectos homogéneos**).

$$\tau_{it}(g) \equiv Y_{it}(g) - Y_{it}(\infty) = \tau, \quad \forall i, t \geq g.$$

Es difícil argumentar que se cumple en la mayoría de los casos.

# El problema de los pesos negativos en TWFE

- **Sólo heterogeneidad temporal:** el efecto depende del tiempo relativo al evento, pero toda unidad a  $j$  periodos post adopción tiene el mismo efecto  $\tau_j$ .
- **TWFE como promedio ponderado:** de Chaisemartin and D'Haultfœuille (2020); Goodman-Bacon (2021) muestran que


$$\tau^{twfe} = \sum_j \omega_j^{twfe} \tau_j, \quad \text{con} \quad \sum_j \omega_j^{twfe} = 1 \text{ pero puede haber } \omega_j^{twfe} < 0.$$

**Pesos pueden ser negativos!**

- **Heterogeneidad en tiempo y unidades:**  $\tau_{it}(g)$  puede recibir *peso negativo* para algunas combinaciones de  $t$  y  $g$ .


# Caracterizando el problema

- **Tres cohortes:** nunca-tratados ( $G_i = U \equiv \infty$ ), tratados temprano ( $G_i = k$ ), tratados tarde ( $G_i = l$ ), con  $k < l$ .



# Descomposición de Goodman-Bacon (2021)

- El estimador de  $\tau^{twfe}$  se descompone como un **promedio ponderado** de todos los posibles estimadores de DiD de  $2 \times 2$  entre cohortes.



- **Comparaciones indebidas:** en una de las comparaciones DiD  $2 \times 2$ , el grupo tratado *tarde* se compara con el grupo tratado *temprano* **después** de que éste ya recibió el tratamiento  $\Rightarrow$  el contrafactual se construye con unidades ya tratadas.

# Descomposición del sesgo en TWFE estático

## ■ Estimando asintótico (Goodman-Bacon, 2021):

$$\text{plim}_{N \rightarrow \infty} \hat{\tau}_{mco}^{twfe} = \underbrace{\text{VWATT}}_{\text{promedio causal}} + \underbrace{\text{VWCT}}_{\text{falta de tendencias paralelas}} - \underbrace{\Delta ATT}_{\text{heterogeneidad}}.$$

1. **VWATT** (*variance-weighted ATT*): promedio ponderado de los efectos causales.
2. **VWCT** (*variance-weighted common trends*): sesgo si no se cumple **tendencias paralelas generalizadas**.
3.  **$\Delta ATT$**  (*heterogeneity bias*): surge cuando el efecto varía por cohorte o por tiempo relativo ( $t - G_i$ ).

## ¿El modelo TWFE dinámico sigue siendo válido?

- Especificación dinámica:

$$Y_{it} = \phi_t + \eta_i + \sum_{j \neq -1} \tau_j^{twfe} D_i \mathbf{1}\{j = t - G_i\} + e_{it}.$$

- Sun and Abraham (2021) muestran que si todas las unidades tienen el mismo efecto en el  $j$ -ésimo período posterior al tratamiento, entonces  $\tau_j^{twfe} = \tau_j$ .

- Con heterogeneidad entre cohortes:

$$\tau_j^{twfe} = \sum_g w_{j,g}^{twfe} ATT(g, g+j), \quad \text{con} \quad \sum_g w_{j,g}^{twfe} = 1,$$

pero los pesos  $w_{j,g}^{twfe}$  dependen del **tamaño de las cohortes** y del **tiempo de adopción**. **¿Cómo interpretarlo?**

## Alternativa (1): Callaway and Sant'Anna (2020)

- **Intuición:** no es necesario hacer la estimación a través de un modelo TWFE.
- Lo único que se necesita es estimar los **ATT por grupo-periodo:**

$$ATT(g, t) = \mathbb{E} [Y_{it}(g) - Y_{it}(\infty) \mid G_i = g],$$

y después agregarlos usando pesos “bien comportados” definidos por el investigador.

- Si se cumplen **S1b**, **S2b** y **S3**:

$$ATT(g, t) = \mathbb{E}[Y_{it} - Y_{ig-1} \mid G_i = g] - \mathbb{E}[Y_{it} - Y_{ig-1} \mid G_i \in \mathcal{G}_{comp}], \quad (1)$$

donde  $\mathcal{G}_{comp}$  puede incluir:

- Unidades **nunca tratadas**:  $\mathcal{G}_{comp} = \{\infty\}$ .
- Unidades **aún no tratadas** en  $t$ :  $\mathcal{G}_{comp} = \{g' : g' > t\}$ .

## Alternativa (1): Callaway and Sant'Anna (2020)

- El estimador es el **análogo muestral** de (1):

$$\widehat{ATT}(g, t) = \frac{1}{N_g} \sum_{i: G_i = g} (Y_{it} - Y_{ig-1}) - \frac{1}{N_{g, \mathcal{G}_{comp}}} \sum_{i: G_i \in \mathcal{G}_{comp}} (Y_{it} - Y_{ig-1}).$$

- ATT por tiempo relativo**  $j = t - G_i \geq 0$ :

$$\widehat{ATT}_j^\omega = \sum_g \omega_g \widehat{ATT}(g, g+j), \quad \text{con } \omega_g \geq 0 \text{ y } \sum_g \omega_g = 1.$$

donde  $\omega_g$  puede ser uniforme (mismo peso a cada cohorte), proporcional al tamaño de la cohorte, o cualquier otra alternativa.

- ATT global (para  $j = t - G_i \geq 0$ ):**

$$\widehat{ATT}^\omega = \sum_j \sum_g \omega_{g,j} \widehat{ATT}(g, g+j), \quad \text{con } \omega_{g,j} \geq 0 \text{ y } \sum_j \sum_g \omega_{g,j} = 1.$$

Aplica el mismo comentario para  $\omega_{g,j}$ .

## Alternativa (2): Sun and Abraham (2021)

- Proponen un estimador basado en un **modelo de regresión saturado**:

$$Y_{it} = \phi_t + \eta_i + \sum_{g \neq \infty} \sum_{j \neq -1} \tau_{g,j}^{SA} \mathbf{1}\{G_i = g\} \times \mathbf{1}\{j = t - g\} + e_{it},$$

- Si se cumplen **S1b**, **S2b** y **S3**,


$$\text{plim } \hat{\tau}_{g,j}^{SA} = ATT(g, g + j)$$

- **Intuición**: el contrafactual se construye utilizando la cohorte  $G_i = \infty$  (no hay **comparaciones indebidas**). Si no existe esa cohorte, se utiliza la cohorte que recibe el tratamiento más tarde ( $g = \max\{t : D_{it} = 1\}$ ).
- Los  $\hat{\tau}_{g,j}$  se pueden agregar usando pesos como en Callaway and Sant'Anna (2020).

## Ejemplo (1): Braghieri et al. (2022)

- Estiman el efecto causal del **uso de redes sociales en la salud mental** de estudiantes universitarios.
- Utilizan la **introducción escalonada de Facebook** en 775 universidades de EE.UU. (2004–2006) como experimento natural.
- Datos: Encuestas del *National College Health Assessment* (NCHA) sobre salud mental (2000–2008).
  - Construyen un **índice de mala salud mental** que resume todas las variables relevantes de la encuesta.

# Resultados de los diferentes estimadores



- Facebook empeora la salud mental:  $+0.085$  desv. estándar.
- Impacto comparable al 22 % del efecto de perder el empleo.
- 24 % del aumento en depresión severa puede explicarse por Facebook.

## Ejemplo (2): Kleven et al. (2019)

- Diferencias importantes entre hombres y mujeres en ingresos laborales, participación laboral, y horas trabajadas (entre otros).
- Parte de la literatura se ha enfocado en identificar si estas diferencias se explican por discriminación, preferencias, normas sociales, patrones de acumulación de capital humano, etc.
- Kleven et al. (2019) estudian el efecto de tener hijos sobre la carrera de las mujeres.

# Estrategia de identificación

- Usan el momento del nacimiento del primer hijo para estudiar los efectos de este “evento” sobre diferentes resultados laborales: ingresos, horas trabajadas, y participación laboral.
  - Se comparan hombres y mujeres antes y después del nacimiento del primer hijo.
  - Diferentes parejas tienen el primer hijo a diferentes edades (diferentes momentos en la carrera).
- Construyen un panel de individuos con datos administrativos de Dinamarca entre 1980 y 2013.
- Identifican parejas para las cuáles hay información de al menos 5 años antes **del nacimiento del primer hijo** y 10 años después.


# Especificación econométrica

- Para cada individuo  $i$  en el año  $s$ , definimos  $t = 0$  como el año en que nace el primer hijo ( $t = -5, \dots, 0, \dots, 10$  indica el tiempo (años) relativo al evento).

$$Y_{ist}^g = \sum_{j \neq -1} \tau_j^g \mathbf{1}\{j = t\} + \sum_k \beta_k^g \mathbf{1}\{k = \text{age}_{is}\} + \eta_s^g + e_{ist}^g$$

- $\mathbf{1}\{k = \text{age}_{is}\}$  son *dummies* de edad, y  $\eta_s^g$  son efectos fijos de año.
- Se estima un modelo diferente para hombres ( $g = m$ ) y mujeres ( $g = w$ ). La “penalidad” de tener un hijo es:

$$P_t = \frac{\hat{\tau}_t^m - \hat{\tau}_t^w}{\mathbb{E}[\hat{Y}_{ist}^w | t]}.$$



1.  $\downarrow$  **ingresos** ( $\approx -30\%$  en  $t = 0$ ) y **salario por hora** ( $\approx -10\%$  en  $t = 0$ ).
2.  $\downarrow$  **horas trabajadas** ( $\approx -12\%$  en  $t = 0$ ).
3.  $\downarrow$  **participación laboral** ( $\approx -12\%$  en  $t = 0$ ).