

Econometría Avanzada

Modelo de Selección de Heckman

Manuel Fernández

9 de julio de 2026

Temas de la clase:


1. Modelos de selección
2. Modelos de utilidad aleatoria
3. Ecuación de selección en el modelo de Heckman
4. Modelo Heckit
5. Anexo


Modelos de selección

Autoselección en la muestra

- Estudiar situaciones en las que **la muestra está seleccionada**, y la **selección depende de decisiones** que toman las unidades.
 - Observamos los resultados laborales únicamente de las personas que **participan en el mercado laboral**.
 - Observamos los resultados de un RCT únicamente para las personas que **participan en el experimento**.
 - Observamos los resultados de una encuesta solo para las **personas que la contestan**.

Sesgo de supervivencia: ¿Dónde poner el blindaje?





Truncamiento incidental

- Queremos estimar los parámetros del modelo

$$Y_i^* = \mathbf{X}_i' \boldsymbol{\beta} + \epsilon_i,$$

donde $\mathbb{E}[\epsilon_i | \mathbf{X}_i] = 0$. Sin embargo, solo observamos Y_i^* para un **subconjunto de la población**.

- Por ejemplo, si Y_i^* es la nota de la evaluación docente, tenemos:

$$Y_i = \begin{cases} Y_i^* & \text{si } i \text{ responde la encuesta} \\ - & \text{si } i \text{ no responde la encuesta.} \end{cases}$$

- **Problema:** responder la encuesta es un **decisión**.

Modelos de utilidad aleatoria

Modelos de utilidad aleatoria (lineal)

- Una posibilidad es pensar la selección en términos de **decisiones óptimas de los agentes**.

1. Cada individuo deriva una **utilidad**, U_i^j , de cada alternativa $j \in \{0, 1\}$ (e.g., responder o no la encuesta).
2. Si la función de utilidad es lineal en los parámetros:

$$U_i^j = \mathbf{Z}_i' \boldsymbol{\gamma}^j + \eta_i^j \quad \text{para } j = 0, 1,$$

donde η_i^j son todos los factores no observados que afectan la utilidad.

3. **Regla de decisión**: el individuo elige la opción que le genera la mayor utilidad:

$$D_i = \begin{cases} 1 & \text{si } U_i^1 \geq U_i^0, \\ 0 & \text{si } U_i^1 < U_i^0. \end{cases}$$

Normalización de las utilidades

- Las funciones de utilidad tienen una **interpretación ordinal** (en la mayoría de los casos). Podemos **simplificar** el problema:

$$\begin{aligned} U_i^* &\equiv U_i^1 - U_i^0 = \mathbf{Z}_i' \underbrace{(\gamma^1 - \gamma^0)}_{\gamma} + \underbrace{(\eta_i^1 - \eta_i^0)}_{\eta_i} \\ &= \mathbf{Z}_i' \gamma + \eta_i \end{aligned}$$

- U_i^* es una variable latente: no se puede observar o medir directamente. Aún así, podemos usar esta estructura.
- La **regla de decisión** ahora es

$$D_i = \begin{cases} 1 & \text{si } U_i^* \geq 0, \\ 0 & \text{si } U_i^* < 0. \end{cases}$$

Especificación de las probabilidades

- Suponga que $\eta_i|\mathbf{Z}_i$ tiene una función de densidad de probabilidad condicional que es simétrica y está centrada en cero.
- Dada la **regla de decisión**:

$$\begin{aligned}\Pr[D_i = 1|\mathbf{Z}_i] &= \Pr[U_i^* \geq 0|\mathbf{Z}_i] \\ &= \Pr[\mathbf{Z}_i'\gamma + \eta_i \geq 0|\mathbf{Z}_i] \\ &= \Pr[\eta_i \geq -\mathbf{Z}_i'\gamma|\mathbf{Z}_i] \\ &= 1 - F(-\mathbf{Z}_i'\gamma), \\ &= F(\mathbf{Z}_i'\gamma)\end{aligned}$$

donde F es la **función de distribución acumulada (CDF)** de $\eta_i|\mathbf{Z}_i$.

Ecuación de selección en el modelo de Heckman

- Supongamos que el estudiante decide responder la encuesta si la utilidad de hacerlo supera la utilidad de no responder:

$$U_i^* = \mathbf{Z}_i' \boldsymbol{\gamma} + \eta_i,$$

donde $\mathbf{X}_i \subseteq \mathbf{Z}_i$ y ambas incluyen una constante.

- Variable indicadora de participación: $D_i = \mathbf{1}\{U_i^* \geq 0\}$, es decir:

$$D_i = \begin{cases} 1 & \text{si } \mathbf{Z}_i' \boldsymbol{\gamma} + \eta_i \geq 0, \\ 0 & \text{si } \mathbf{Z}_i' \boldsymbol{\gamma} + \eta_i < 0. \end{cases}$$

Problema de selección

$$Y_i^* = \mathbf{X}_i' \beta + \epsilon_i \quad (\text{ecuación de interés})$$

$$U_i^* = \mathbf{Z}_i' \gamma + \eta_i \quad (\text{ecuación de selección}).$$

- **Problema:** puede que ϵ_i y η_i no sean independientes.

$$\begin{aligned} \mathbb{E}[Y_i | \mathbf{X}_i] &= \mathbb{E}[Y_i^* | \mathbf{X}_i, D_i = 1] \\ &= \mathbf{X}_i' \beta + \mathbb{E}[\epsilon_i | \mathbf{X}_i, \eta_i \geq -\mathbf{Z}_i' \gamma]. \end{aligned}$$

El estimador por MCO es (generalmente) sesgado e inconsistente.

- Heckman (1979) propone pensar en el último término **como si fuera una variable omitida**: controlar por esa variable sería análogo a controlar por el **sesgo de selección**.



- Nobel en 2000 “*for his development of theory and methods for analyzing **selective samples.***”

Razón de Mills inversa (IMR)

- Sea W una variable aleatoria con una **distribución normal estándar**, y sea k una constante. Entonces (ver  **anexo**):

$$1. \mathbb{E}[W \mid W < k] = -\frac{\phi(k)}{\Phi(k)},$$


$$2. \mathbb{E}[W \mid W > k] = \frac{\phi(k)}{1 - \Phi(k)},$$

donde $\phi(\cdot)$ y $\Phi(\cdot)$ denotan, respectivamente, la función de densidad (pdf) y la función de distribución acumulada (cdf) de la normal estándar.

- La función $\lambda(k) \equiv \frac{\phi(k)}{\Phi(k)}$ se conoce como la *razón de Mills inversa (IMR)*.

También se define la versión complementaria $\lambda^*(k) = \frac{\phi(k)}{1 - \Phi(k)}$.

Ejemplo del valor esperado de W si $W > 0$ (i.e., $k = 0$)



- $\phi(0) \approx 0.4$
- $\Phi(0) = 0.5$
- $\lambda^*(0) \approx 0.4/0.5 \approx 0.8$

Propiedades útiles de la normal bivariada

- Suponga que tiene dos variables aleatorias, Z y W , tal que

$$\begin{pmatrix} Z \\ W \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_z \\ \mu_w \end{pmatrix}, \begin{pmatrix} \sigma_z^2 & \rho \cdot \sigma_w \cdot \sigma_z \\ \rho \cdot \sigma_w \cdot \sigma_z & \sigma_w^2 \end{pmatrix} \right).$$

- Entonces

1. **Marginal de W :**

$$W \sim \mathcal{N}(\mu_w, \sigma_w^2)$$

2. **Condicional de Z :**

$$Z|W \sim \mathcal{N} \left(\mu_z + \rho \frac{\sigma_z}{\sigma_w} (W - \mu_w), (1 - \rho^2) \sigma_z^2 \right).$$

Modelo Heckit

Supuesto distribucional

$$Y_i^* = \mathbf{X}_i' \beta + \epsilon_i \quad (\text{ecuación de interés})$$

$$U_i^* = \mathbf{Z}_i' \gamma + \eta_i \quad (\text{ecuación de selección}).$$

- Suponemos que ϵ_i y η_i tienen una **distribución normal bivariada**:

$$\begin{pmatrix} \epsilon_i \\ \eta_i \end{pmatrix} \middle| \mathbf{x}_i, \mathbf{z}_i \sim \mathcal{N} \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2 & \rho \cdot \sigma \\ \rho \cdot \sigma & 1 \end{pmatrix} \right).$$

donde ρ es la correlación entre las dos variables.

- La varianza del término de error en la ecuación de participación se normaliza a uno: fija la escala de la variable latente U_i^* .

Aplicando las propiedades

- En el contexto del modelo

$$\begin{pmatrix} \epsilon_i \\ \eta_i \end{pmatrix} \Big| \mathbf{x}_i, \mathbf{z}_i \sim \mathcal{N} \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2 & \rho \cdot \sigma \\ \rho \cdot \sigma & 1 \end{pmatrix} \right),$$

entonces, omitiendo los condicionales para simplificar la notación,

1. Marginal de η_i :

$$\eta_i \sim \mathcal{N}(0, 1)$$

2. Condicional de ϵ_i :

$$\epsilon_i | \eta_i \sim \mathcal{N}(\rho \sigma \eta_i, (1 - \rho^2) \sigma^2)$$

En particular: $\mathbb{E}[\epsilon_i | \eta_i] = \rho \sigma \eta_i$.

- Retomando, tenemos que

$$\begin{aligned}\mathbb{E}[Y_i|\mathbf{X}_i, \mathbf{Z}_i] &= \mathbb{E}[Y_i^*|\mathbf{X}_i, \mathbf{Z}_i, D_i = 1] \\ &= \mathbf{X}_i'\beta + \mathbb{E}[\epsilon_i|\mathbf{X}_i, \mathbf{Z}_i, \eta_i \geq -\mathbf{Z}_i'\gamma].\end{aligned}$$

- Pero $\mathbb{E}[\epsilon_i|\eta_i] = \rho\sigma\eta_i$, así que

$$\begin{aligned}\mathbb{E}[Y_i|\mathbf{X}_i, \mathbf{Z}_i] &= \mathbf{X}_i'\beta + \rho\sigma \mathbb{E}[\eta_i|\mathbf{X}_i, \mathbf{Z}_i, \eta_i \geq -\mathbf{Z}_i'\gamma] \\ &= \mathbf{X}_i'\beta - \rho\sigma \mathbb{E}[-\eta_i|\mathbf{X}_i, \mathbf{Z}_i, -\eta_i \leq \mathbf{Z}_i'\gamma] \\ &= \mathbf{X}_i'\beta + \rho\sigma \frac{\phi(\mathbf{Z}_i'\gamma)}{\Phi(\mathbf{Z}_i'\gamma)} \\ &= \mathbf{X}_i'\beta + \rho\sigma\lambda(\mathbf{Z}_i'\gamma)\end{aligned}$$

donde $\lambda(\cdot)$ es el *IMR*.

$$\mathbb{E}[Y_i|\mathbf{X}_i, \mathbf{Z}_i] = \mathbf{X}_i'\beta + \rho\sigma\lambda(\mathbf{Z}_i'\gamma).$$

- Definamos $\beta_\lambda \equiv \rho\sigma$ y $\lambda_i \equiv \lambda(\mathbf{Z}_i'\gamma)$. El valor esperado condicional (CEF) queda

$$\mathbb{E}[Y_i|\mathbf{X}_i, \mathbf{Z}_i] = \mathbf{X}_i'\beta + \beta_\lambda\lambda_i$$

- Si tuviéramos la variable λ_i , podríamos plantear el modelo lineal

$$Y_i = \mathbf{X}_i'\beta + \beta_\lambda\lambda_i + \zeta_i,$$

donde, por las propiedades de la CEF, $\mathbb{E}[\zeta_i|\mathbf{X}_i, \mathbf{Z}_i] = 0$.

- Recordemos la forma como modelamos la decisión de participación:

$$D_i = \begin{cases} 1 & \text{si } \mathbf{Z}_i' \boldsymbol{\gamma} + \eta_i \geq 0 \\ 0 & \text{si } \mathbf{Z}_i' \boldsymbol{\gamma} + \eta_i < 0, \end{cases}$$

- Por el supuesto distribucional, $\eta_i \sim \mathcal{N}(0, 1)$. Entonces

$$\begin{aligned} \Pr[D_i = 1 | \mathbf{Z}_i] &= \Pr[\eta_i \geq -\mathbf{Z}_i' \boldsymbol{\gamma}] \\ &= \Phi(\mathbf{Z}_i' \boldsymbol{\gamma}) \end{aligned}$$

Podemos estimar los parámetros $\boldsymbol{\gamma}$ usando un modelo **probit**.

Estimador de Heckman en dos etapas

- Las dos etapas:
 1. Estimar los parámetros γ usando un modelo **Probit**.
 2. Con los parámetros estimados, calcular

$$\hat{\lambda}_i = \frac{\phi(\mathbf{Z}_i' \hat{\gamma})}{\Phi(\mathbf{Z}_i' \hat{\gamma})},$$

y estimar

$$Y_i = \mathbf{X}_i' \beta + \beta_\lambda \hat{\lambda}_i + \zeta_i,$$

por MCO.

- Heckman (1979) Sample selection bias as a **specification error**. *Econometrica*, 47(1): 153-161.


1. Hay heterocedasticidad y el estimador de White-Huber no resuelve el problema. Se puede usar **bootstrap** u otras correcciones.
2. El modelo se puede estimar por máxima verosimilitud.
 - Más eficiente.
 - Los errores estándar estimados se pueden usar directamente.
 - Menos *robusto* al ser más dependiente de los supuestos de identificación: esperanza condicional (dos etapas) vs. distribución conjunta (máxima verosimilitud).

Problema de identificación

- Suponga que $\mathbf{Z}_i = \mathbf{X}_i$, i.e., el vector de variables en la **ecuación de interés** es el mismo de la **ecuación de selección**. Tenemos

$$\mathbb{E}[Y_i | \mathbf{X}_i] = \mathbf{X}_i' \boldsymbol{\beta} + \beta_\lambda \lambda_i; \quad \lambda_i \equiv \lambda(\mathbf{X}_i' \boldsymbol{\gamma}).$$

- **Problema:** La **IMR** es casi lineal en rangos centrales:



Problema de identificación 2

- Esto implica que

$$\lambda_i \approx \alpha_0 + \alpha_1 \mathbf{X}_i' \boldsymbol{\gamma},$$

y que

$$\begin{aligned}\mathbb{E}[Y_i | \mathbf{X}_i] &\approx \mathbf{X}_i' \boldsymbol{\beta} + \beta_\lambda (\alpha_0 + \alpha_1 \mathbf{X}_i' \boldsymbol{\gamma}) \\ &= \alpha_0 + \mathbf{X}_i' \boldsymbol{\beta}^*\end{aligned}$$

donde $\boldsymbol{\beta}^* = \boldsymbol{\beta} + \beta_\lambda \alpha_1 \boldsymbol{\gamma}$.

- **Implicación:** No podríamos estimar de forma separada β_λ y $\boldsymbol{\beta}$ a menos que el valor del índice capture parte de la no linealidad de la *IMR*. La identificación viene de la **forma funcional!**

Heckman y variables instrumentales

- Las exclusiones $\mathbf{X}_i \subset \mathbf{Z}_i$ facilitan la identificación; en particular, requerimos covariables en $\mathbf{Z}_i$ que no estén en $\mathbf{X}_i$.
- Una exclusión implica contar con una variable observada que afecta la probabilidad de responder (selección), pero no afecta directamente la nota que el estudiante reporta (resultado). En la práctica, **necesitamos un instrumento** que cumpla relevancia y validez (recordar criterios de una buena VI).
- Estrictamente, no es una condición necesaria para identificar bajo supuestos fuertes (p. ej., normalidad conjunta), pero sí es altamente recomendable para una identificación creíble y mayor precisión.

Anexo

Valor esperado de una variable aleatoria normal estándar truncada.

- Recordemos que:

$$\phi(W) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{W^2}{2}\right),$$
$$\frac{d\phi(W)}{dW} = -W \cdot \phi(W).$$

Valor esperado de una normal estándar truncada

- Para una constante k , el valor esperado condicional es:

$$\begin{aligned}\mathbb{E}[W \mid W < k] &= \int_{-\infty}^k W \cdot f(W \mid W < k) dW \\ &= \frac{1}{\Phi(k)} \int_{-\infty}^k W \cdot \phi(W) dW \\ &= \frac{-1}{\Phi(k)} \int_{-\infty}^k \frac{d\phi(W)}{dW} dW \\ &= \frac{-1}{\Phi(k)} [\phi(W)]_{-\infty}^k \\ &= -\frac{\phi(k)}{\Phi(k)}.\end{aligned}$$

- En este curso, los estudiantes aprenderán y practicarán **técnicas microeconómicas de punta** empleadas en el trabajo aplicado, con un enfoque en la **estimación de efectos causales**

Resultados de aprendizaje

1. **Formular** estrategias para abordar problemas de identificación en ejercicios econométricos de inferencia causal
2. **Evaluar** críticamente la validez de una estrategia de identificación en un contexto específico de estimación
3. **Realizar** estimaciones de modelos econométricos utilizando herramientas como Stata, R o Python
4. **Interpretar** correctamente los resultados de un ejercicio econométrico
5. **Diferenciar** y **evaluar** la validez interna y externa en un ejercicio de estimación
6. **Comunicar** efectivamente los resultados de una estimación econométrica.
7. **Realizar** análisis de sensibilidad y robustez